МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ государственное БЮДЖЕТНОЕ

образовательное учреждение

высшего образования

«НОВОСИБИРСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Кафедра автоматизированных систем управления



ОТЧЁТ

по лабораторной работе №1

по дисциплине: «*Методы анализа данных***»**

Выполнили работу:
Студент группы АП-326, АВТФ
Шервашидзе М.В.

«___» _____ 20__г
_____
(подпись)

Проверил работу:
Доцент каф. АСУ
Ганелина Н.Д.

«___» _____ 20__г
_____
(подпись)

Новосибирск 2026

Содержание

Содержание ... 2
Цель работы ... 3
Описание исходных данных ... 4
Лабораторная работа 1.1. Описательная статистика и корреляционный анализ ... 5
Дескриптивный анализ и проверка нормальности ... 5
Гистограммы. Формула Стерджесса ... 7
Таблицы сопряжённости ... 8
Корреляционный анализ ... 8
Различия коэффициентов для разных типов переменных ... 11
Соотношение понятий «зависимость» и «корреляция» ... 11
Ложная корреляция ... 12
Лабораторная работа 1.2. Регрессионный анализ ... 15
Линейная модель с фиктивными переменными ... 15
Пуассоновская регрессия ... 17
Нелинейная модель ... 19
Сравнение моделей ... 20
Лабораторная работа 1.3. Дисперсионный анализ ... 21
Правила и условия применения ... 21
Формулировка гипотез и градации фактора ... 21
Однофакторный ANOVA ... 21
Критерий Краскела–Уоллиса ... 22
Двухфакторный дисперсионный анализ ... 22
Заключение ... 24
Код программы ... 25
Список литературы ... 36

Цель работы

Цель работы — освоить методы дескриптивного анализа, проверку согласованности выборки с нормальным законом, корреляционный анализ (включая ранговый), построение и диагностику регрессионных моделей (линейной с фиктивными переменными, пуассоновской и нелинейной), а также однофакторный и двухфакторный дисперсионный анализ и критерий Краскела–Уоллиса. Отдельно рассматривается явление ложной корреляции.

Среда выполнения: Python 3 (библиотеки pandas, NumPy, SciPy, statsmodels, matplotlib, seaborn). Расчёты воспроизводятся скриптом lab1.py.

Описание исходных данных

В качестве основного массива выбран набор Wine Quality репозитория UCI Machine Learning Repository (рекомендуемый в методичке источник №7). Объединены выборки красного (n = 1599) и белого (n = 4898) вина; итоговый объём N = 6497 наблюдений. Набор содержит физико-химические характеристики вин и экспертную оценку качества по шкале от 0 до 10.

Для выполнения работы использовались 3–4 признака, включая категориальный:

— зависимая переменная: quality (оценка качества, баллы) — порядковая/счётная;

— независимые количественные: alcohol (крепость, % об.), volatile acidity (летучая кислотность, г/дм³), residual sugar (остаточный сахар, г/дм³);

— категориальная: type (тип вина: красное / белое) — используется как фиктивная переменная в регрессии и как второй фактор в двухфакторном ANOVA.

Предметная гипотеза: более высокая крепость и более низкая летучая кислотность связаны с более высокой оценкой качества; тип вина может смещать уровень оценки. Для дисперсионного анализа зависимой переменной выступает крепость, фактором — группа качества.

Лабораторная работа 1.1. Описательная статистика и корреляционный анализ

Дескриптивный анализ и проверка нормальности

Показатель	Крепость	Лет. кислотность	Ост. сахар	Качество
Объём n	6497	6497	6497	6497
Среднее	10,492	0,340	5,443	5,818
Медиана	10,300	0,290	3,000	6,000
Мода	9,500	0,280	2,000	6,000
Ст. отклонение	1,193	0,165	4,758	0,873
Дисперсия	1,423	0,027	22,637	0,763
Минимум	8,000	0,080	0,600	3,000
Максимум	14,900	1,580	65,800	9,000
Асимметрия	0,566	1,495	1,435	0,190
Эксцесс (excess)	-0,532	2,825	4,359	0,232

Таблица 1 – Дескриптивный анализ выбранных признаков

Для крепости среднее (10,492 % об.) близко к медиане (10,300), асимметрия положительная (0,566): распределение слегка скошено вправо, что видно и по Q–Q графику. Летучая кислотность и остаточный сахар имеют выраженную правостороннюю асимметрию и положительный эксцесс: «острый» пик у малых значений и длинный правый хвост (для сахара максимум 65,8 г/дм³ при медиане 3,0). Оценка качества дискретна (3–9 баллов), среднее 5,82, мода и медиана равны 6; асимметрия невелика, но дискретность делает нормальную модель неприемлемой.

В нормальном законе среднее совпадает с медианой, асимметрия и эксцесс (excess) равны нулю. Отклонения этих характеристик, а также ящики с усами с выбросами уже на описательном уровне указывают на несогласованность выборок с нормальным распределением.

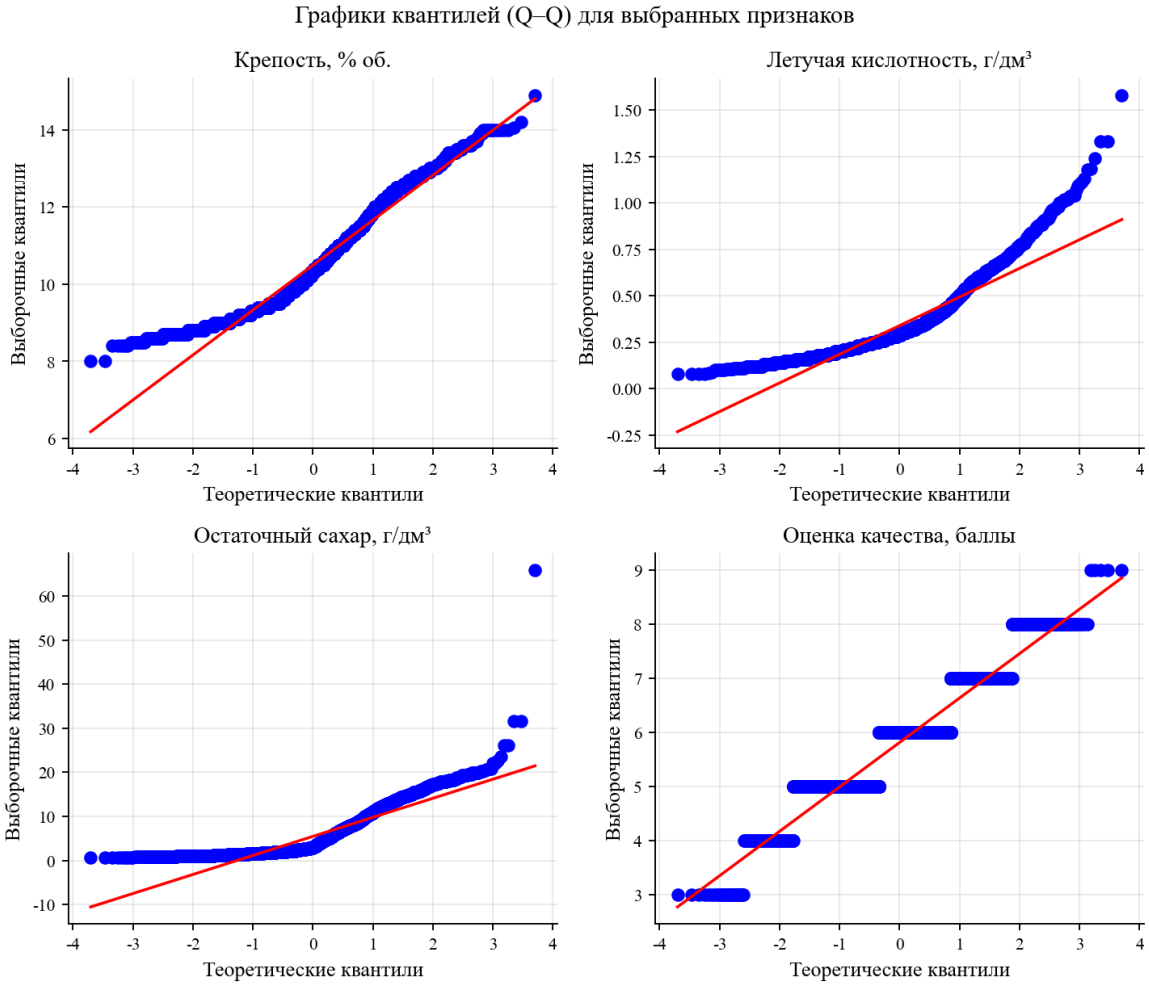


Рисунок 1 – Графики квантилей (Q–Q) для выбранных признаков

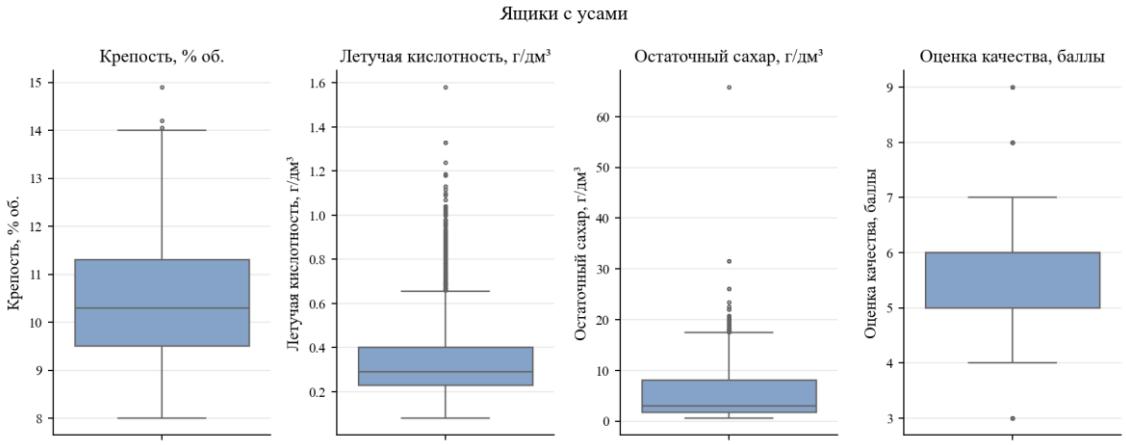


Рисунок 2 – Ящики с усами

Признак	Shapiro–Wilk p	D'Agostino p	Lilliefors p	Вывод
Крепость	$< 1 \cdot 10^{-16}$	$< 1 \cdot 10^{-16}$	0,0010	не нормально
Лет. кислотность	$< 1 \cdot 10^{-16}$	$< 1 \cdot 10^{-16}$	0,0010	не нормально
Ост. сахар	$< 1 \cdot 10^{-16}$	$< 1 \cdot 10^{-16}$	0,0010	не нормально
Качество	$< 1 \cdot 10^{-16}$	1,16e-11	0,0010	не нормально

Таблица 2 – Проверка согласованности с нормальным законом (α = 0,05)

Критерий Шапиро–Уилка при n > 5000 применялся к случайной подвыборке объёма 5000 (фиксированное зерно ГСЧ). Критерий Д'Агостино–Пирсона и критерий Лиллиефорса (модификация Колмогорова–Смирнова при оцениваемых параметрах) считались по полной выборке. Во всех случаях p-value ≪ 0,05, нулевая гипотеза о нормальности отвергается. Следовательно, для корреляционного анализа предпочтителен ранговый подход (Спирмен, Кендалл), а для сравнения групп — непараметрический критерий Краскела–Уоллиса наряду с классическим ANOVA.

Гистограммы. Формула Стерджесса

Число интервалов группировки вычислено по формуле Стерджесса k = 1 + 3,322·lg(n). При n = 6497 получаем k = 13. Длина интервала h = (x_max − x_min) / k. Для крепости h ≈ 0,531 % об., для летучей кислотности h ≈ 0,115 г/дм³, для остаточного сахара h ≈ 5,015 г/дм³, для качества h ≈ 0,462 балла.

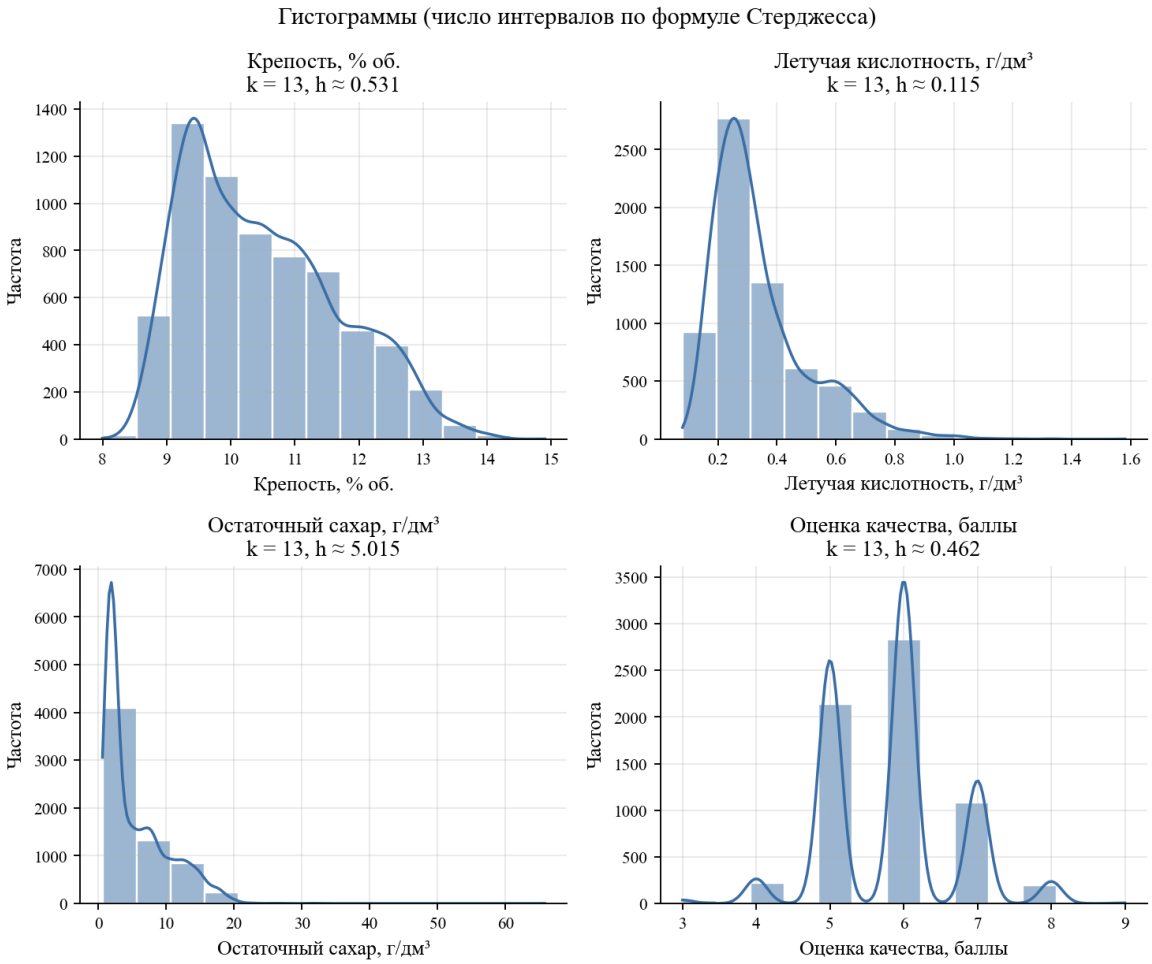


Рисунок 3 – Гистограммы выбранных атрибутов (группировка Стерджесса)

Гистограммы подтверждают выводы дескриптивного анализа: крепость имеет правосторонний скос; кислотность и сахар — резко асимметричны; качество — мультимодальное дискретное распределение с доминированием оценок 5–7. Гистограмма связана с функцией плотности: при увеличении n и измельчении интервалов относительные частоты стремятся к f(x). Для дискретного качества гистограмма по сути является столбчатой диаграммой частот.

Таблицы сопряжённости

Категориальные признаки: тип вина (две градации) и оценка качества (баллы 3–9, уже категориальные). Нулевая гипотеза критерия независимости χ^2: тип вина и оценка качества независимы, то есть P(тип, качество) = P(тип)·P(качество). Наблюдаемые частоты приведены на рисунке 4, теоретические — в таблице 3. Правило отклонения: если χ^2_набл > χ^2_крит(α; df) или p < α, H_0 отвергается.

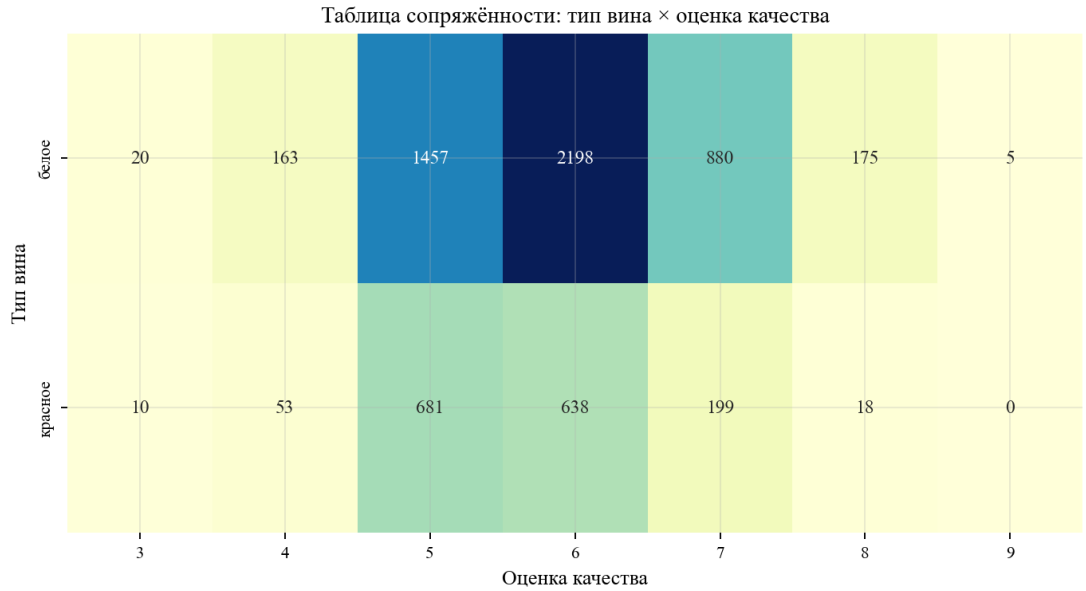


Рисунок 4 – Наблюдаемые частоты таблицы сопряжённости

Тип / качество	3	4	5	6	7	8	9
белое	22,62	162,84	1611,81	2138,02	813,44	145,50	3,77
красное	7,38	53,16	526,19	697,98	265,56	47,50	1,23

Таблица 3 – Теоретические частоты при гипотезе независимости

Статистика Пирсона $\chi^2 = 116{,}54$ при df = 6, $p = < 1 \cdot 10^{-16}$. На уровне $\alpha = 0{,}05$ нулевая гипотеза независимости отвергается. Коэффициент Крамера V = 0,134 — связь статистически значима, но по силе слабая: тип вина смещает распределение оценок (у красного относительно больше «пятёрок», у белого — высоких баллов), однако качество определяется в первую очередь физико-химическими признаками, а не цветом. Замечание: для качества 9 теоретическая частота красного вина меньше 5, поэтому интерпретация крайних клеток осторожная; на общий вывод о зависимости это не влияет из-за большого χ^2.

Корреляционный анализ

Поскольку ни одна количественная выборка не согласуется с нормальным законом, основным является ранговый коэффициент Спирмена; Пирсон приводится для сравнения линейной связи, Кендалл — как более устойчивый на совпадающих рангах. Значимость коэффициента проверялась по $t = r\sqrt{(n-2)}/\sqrt{(1-r^2)}$ при df = n−2 и двусторонней альтернативе; критическое значение $t_{0{,}025;6495} \approx 1{,}96$. Сила связи оценивалась по шкале Чеддока.

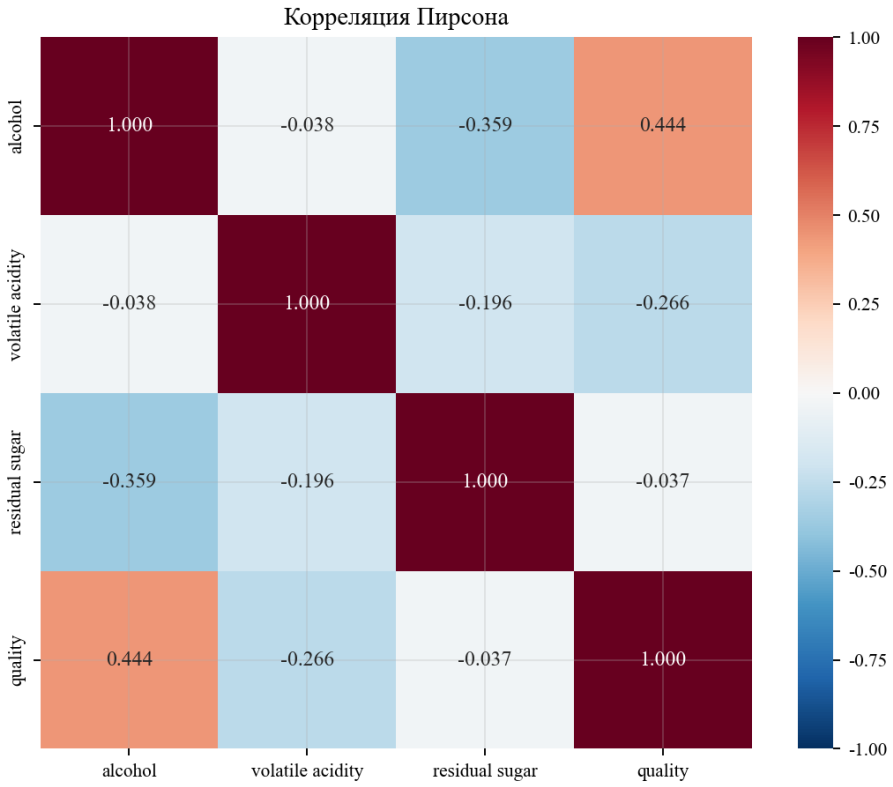


Рисунок 5 – Матрица корреляций Пирсона

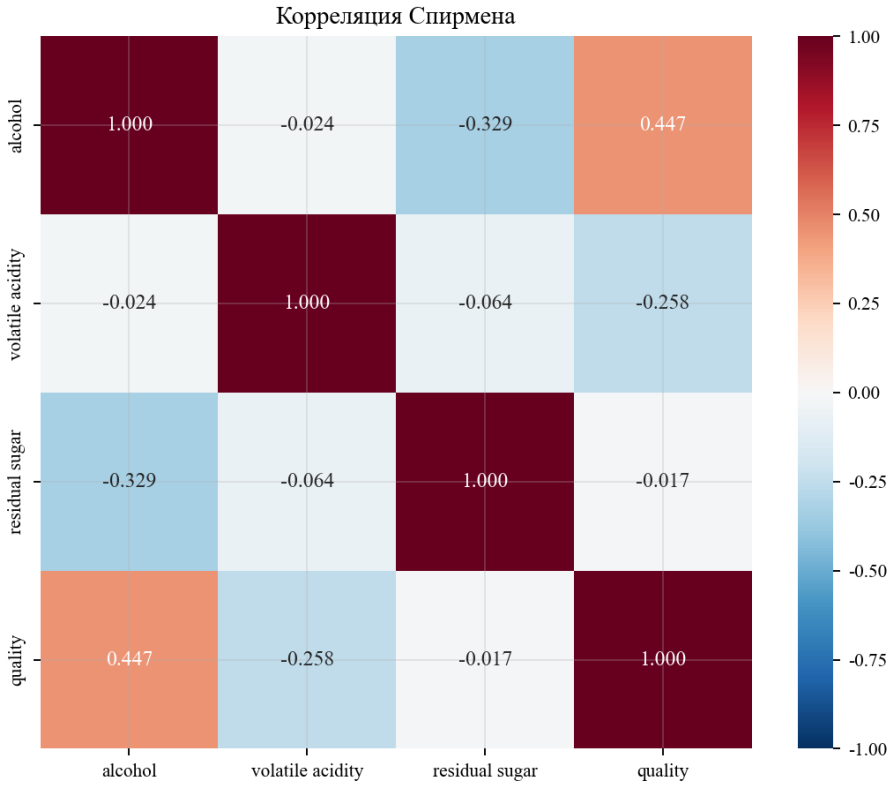


Рисунок 6 – Матрица корреляций Спирмена

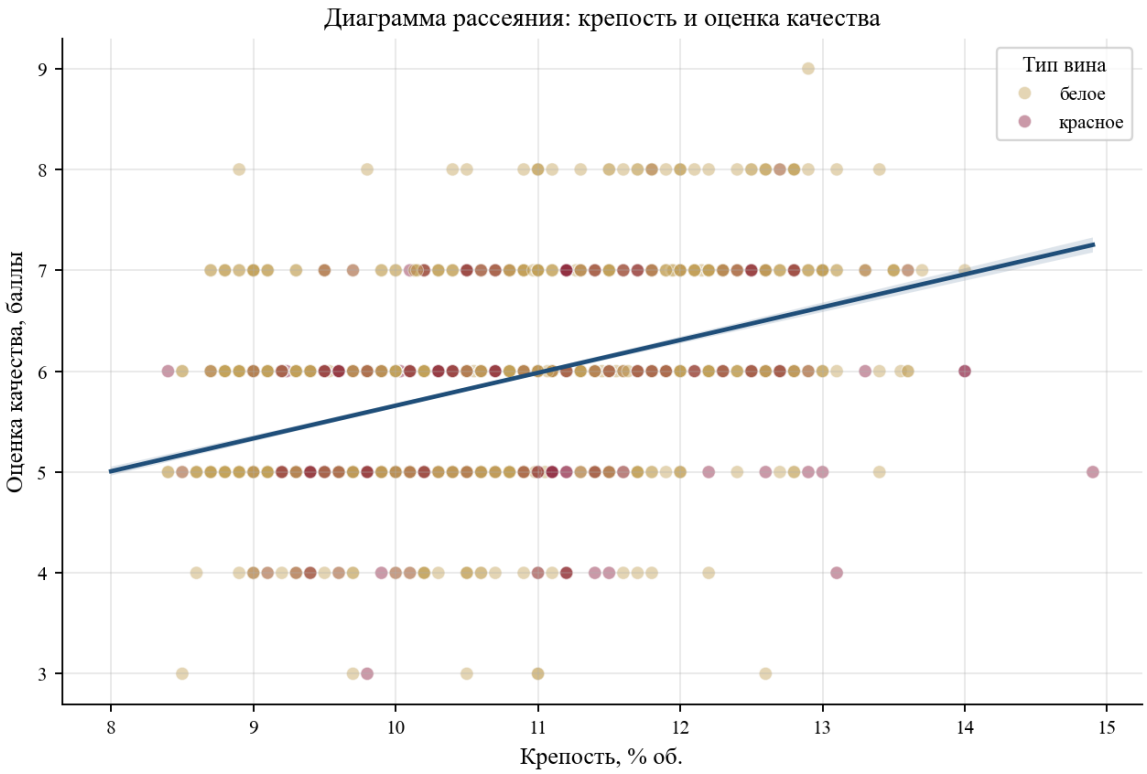


Рисунок 7 – Диаграмма рассеяния крепости и оценки качества

Пара	Пирсон r (p)	Спирмен ρ (p)	Кендалл τ (p)	Сила (ρ)
Крепость — качество	0,444 (< $1\cdot10^{-16}$)	0,447 (< $1\cdot10^{-16}$)	0,352 (< $1\cdot10^{-16}$)	умеренная
Кислотность — качество	-0,266 (< $1\cdot10^{-16}$)	-0,258 (< $1\cdot10^{-16}$)	-0,199 (< $1\cdot10^{-16}$)	слабая
Сахар — качество	-0,037 (0,0029)	-0,017 (0,1734)	-0,013 (0,1688)	практически отсутствует
Крепость — сахар	-0,359 (< $1\cdot10^{-16}$)	-0,329 (< $1\cdot10^{-16}$)	-0,226 (< $1\cdot10^{-16}$)	умеренная
Крепость — кислотность	-0,038 (0,0024)	-0,024 (0,0538)	-0,013 (0,1113)	практически отсутствует
Кислотность — сахар	-0,196 (< $1\cdot10^{-16}$)	-0,064 (2,06e-07)	-0,053 (3,13e-10)	практически отсутствует

Таблица 4 – Коэффициенты корреляции и их значимость

Сильно/заметно коррелированные признаки. Крепость и качество: $\rho = 0{,}447$, $p < 1\cdot10^{-16}$, связь умеренная положительная и статистически значимая ($|\rho| = 0{,}447 > r_{крит} = 0{,}022$). Это согласуется с предметной логикой: более спиртуозные вина чаще получают высокие баллы. Крепость и остаточный сахар: $\rho = -0{,}329$ — умеренная отрицательная связь (сладкие вина в выборке, как правило, менее крепкие).

Слабо коррелированные признаки. Летучая кислотность и качество: $\rho = -0{,}258$ — слабая отрицательная, но значимая связь (избыток уксусной кислоты ухудшает оценку). Сахар и качество: $\rho = -0{,}017$, $p = 0{,}1734$ — связь практически отсутствует и для Спирмена незначима. Крепость и кислотность практически некоррелированы.

Таким образом, наиболее информативный предиктор качества — крепость, полезный дополнительный — летучая кислотность; остаточный сахар как

линейный/монотонный предиктор качества слаб, но может понадобиться как контрольная переменная (он связан с крепостью).

Различия коэффициентов для разных типов переменных

Числовые переменные. Коэффициент Пирсона измеряет силу именно линейной связи и предполагает (для выводов о значимости в классической постановке) двумерную нормальность. При выбросах и нелинейности он смещается.

Ранговые (порядковые) переменные. Коэффициенты Спирмена и Кендалла работают с рангами, устойчивы к монотонным преобразованиям и не требуют нормальности. Спирмен — корреляция Пирсона по рангам; Кендалл основан на числе согласованных и несогласованных пар и предпочтителен при большом числе совпадающих рангов и малых выборках. Оценка качества — типичный порядковый признак, поэтому Спирмен/Кендалл здесь уместнее Пирсона.

Категориальные переменные. Для номинальных шкал применяют таблицы сопряжённости и критерий χ^2, меру Крамера V, иногда коэффициент сопряжённости Пирсона. Корреляция Пирсона к «тип вина — качество» напрямую не применяется: тип сначала кодируют (фиктивные переменные) либо анализируют через сопряжённость, как выше.

Соотношение понятий «зависимость» и «корреляция»

Корреляция измеряет степень линейной (Пирсон) или монотонной (Спирмен) связи. Нулевая корреляция означает отсутствие связи данного вида, но не независимость: возможна нелинейная зависимость (например, $y = x^2$ на симметричном интервале), при которой $r \approx 0$. Некоррелированность эквивалентна независимости в многомерном нормальном законе и, шире, при эллиптических распределениях; вне этого класса эквивалентности нет.

Независимость — отсутствие любой стохастической связи: условное распределение одной величины не зависит от другой. Из независимости всегда следует некоррелированность, обратное верно не всегда. В наших данных сахар и качество почти некоррелированы, однако это не доказательство независимости: связь может проявляться внутри типов вина или через другие переменные (коллидер/конфаундер).

Ложная корреляция

По заданию с сайта http://www.tylervigen.com/spurious-correlations выбран классический пример: душевое потребление сыра в США (фунты/чел. в год) и число смертей от запутывания в простынях (2000–2009 гг.). Переменные не имеют содержательной причинно-следственной связи; оба ряда сонаправленно растут во времени. Вместо календарных подписей на вспомогательных графиках использовались отсчёты t = 1, 2, …, 10; из-за разного масштаба рядов применена вспомогательная ось.

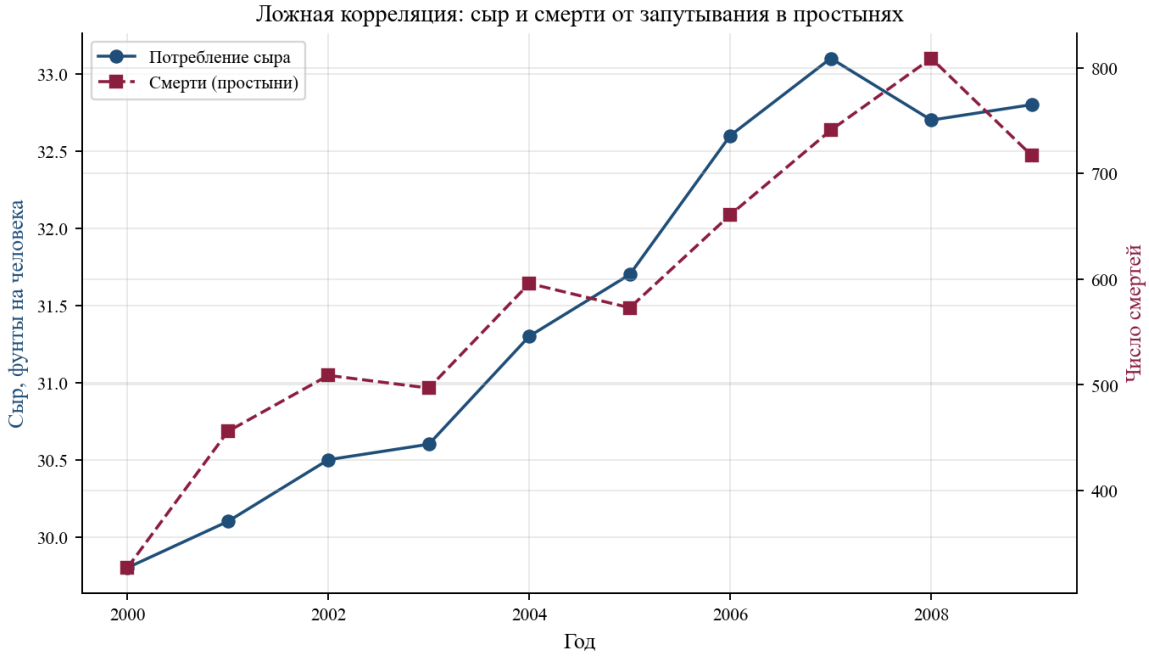


Рисунок 8 – Исходные ряды ложной корреляции (две оси)

Год	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
Сыр, фунт/чел.	29,8	30,1	30,5	30,6	31,3	31,7	32,6	33,1	32,7	32,8
Смерти	327	456	509	497	596	573	661	741	809	717

Таблица 5 – Данные ложной корреляции (T. Vigen)

Коэффициент Пирсона исходных рядов r = 0,947 (весьма высокая связь по Чеддоку), t = 8,35, t_крит = 2,306 при df = 8, p = 3,22e-05. Гипотеза о нулевой корреляции формально отвергается — типичная ловушка «correlation is not causation».

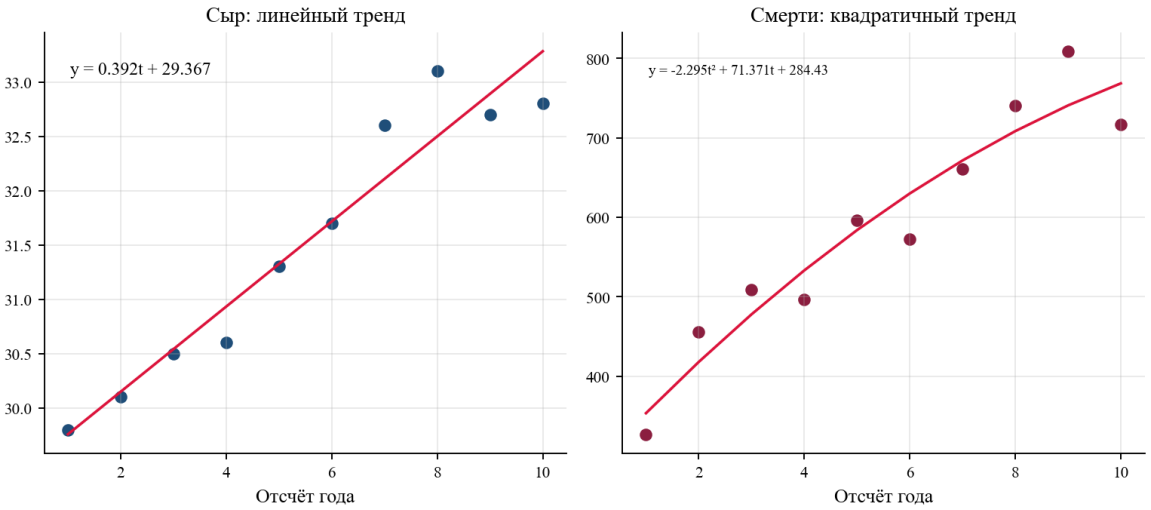


Рисунок 9 – Линии тренда и уравнения моделей

Для сыра наилучшей оказалась линейная модель y = 0.392t + 29.367; для смертей — квадратичная y = -2.295t² + 71.371t + 284.43 (линейный тренд оставлял систематическую кривизну). По уравнениям рассчитаны прогнозные значения ŷ, остатки e = y − ŷ и стандартизированные остатки e / s_e.



Рисунок 10 – Остатки после удаления трендов

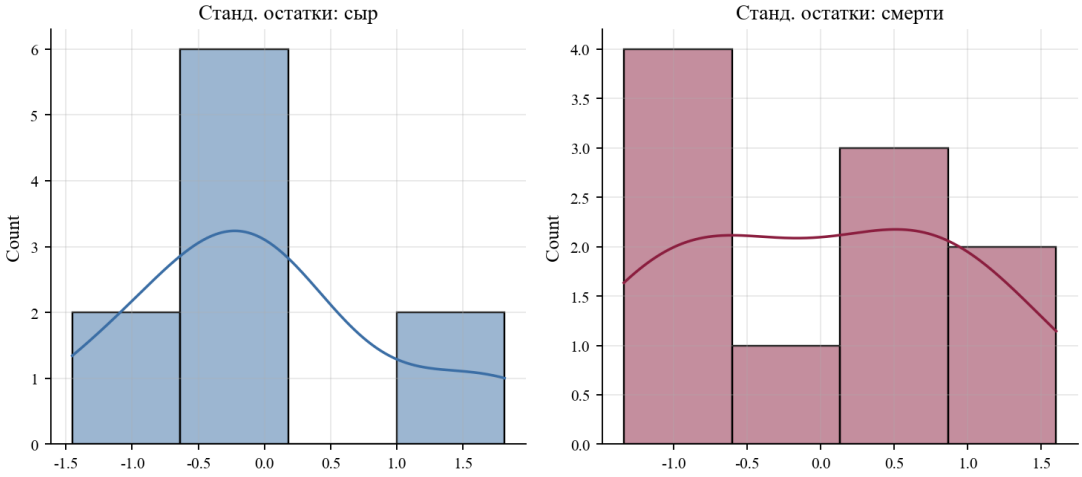


Рисунок 11 – Гистограммы стандартизированных остатков

Корреляция остатков r = 0,272 (слабая), t = 0,80 < t_крит = 2,306, p = 0,4464. После удаления трендов связь становится незначимой. Вывод: наблюдавшаяся «весьма высокая» корреляция порождена общим временны́м трендом (confounding by time), а не причинным механизмом. Другие типичные причины ложной корреляции — множественное сравнение (data dredging на tylervigen.com), малый n, выбросы, автокоррелированные наблюдения и скрытая третья переменная. Гипотеза о причине ложной корреляции в данном примере подтверждается: достаточно детрендировать ряды, чтобы «связь» исчезла.

Лабораторная работа 1.2. Регрессионный анализ

Тип зависимой переменной quality — целочисленная оценка 3–9. Для неё допустимы и линейная модель (как приближение порядковой регрессии при большом n), и пуассоновская (счётный отклик). Категориальный предиктор type кодируется фиктивной переменной D_красное = 1 для красного вина (базовый уровень — белое). Нелинейная спецификация строится свёрткой нелинейных элементов крепости: $alcohol^2$, $alcohol^3$, $alcohol^2 \cdot \ln(alcohol)$, как рекомендовано в задании.

Линейная модель с фиктивными переменными

Оценённая методом наименьших квадратов модель:

$$quality = 2.4901 + 0.3040 \cdot D_{красное} + 0.3532 \cdot alcohol - 1.7017 \cdot volatile_acidity + 0.0231 \cdot residual_sugar$$

Коэффициент детерминации $R^2 = 0{,}277$, скорректированный $R^2_{adj} = 0{,}277$: модель объясняет около 27,7 % вариации оценки качества. $F = 621{,}9$ при $df_1 = 4$, $df_2 = 6492$, $p < 1 \cdot 10^{-16}$ — уравнение в целом значимо. Все коэффициенты значимы на уровне 0,05 (таблица 6). RMSE = 0,742 балла, среднее остатков ≈ 0.

Коэффициент	Оценка	Ст. ошибка	t	p-value
Свободный член	2,4901	0,0979	25,44	$< 1 \cdot 10^{-16}$
Dкрасное	0,3040	0,0299	10,18	$< 1 \cdot 10^{-16}$
alcohol	0,3532	0,0084	41,95	$< 1 \cdot 10^{-16}$
volatile acidity	-1,7017	0,0740	-23,00	$< 1 \cdot 10^{-16}$
residual sugar	0,0231	0,0023	10,25	$< 1 \cdot 10^{-16}$

Таблица 6 – Оценки линейной модели и значимость коэффициентов

Интерпретация: при прочих равных рост крепости на 1 % об. повышает ожидаемую оценку на 0,353 балла; рост летучей кислотности на 1 г/дм³ снижает её на 1,702 балла; красное вино, при тех же физико-химических показателях, оценивается в среднем на 0,304 балла выше белого. Положительный коэффициент при сахаре мал по величине: сахар слабо связан с качеством напрямую, но корректирует смешение с крепостью.

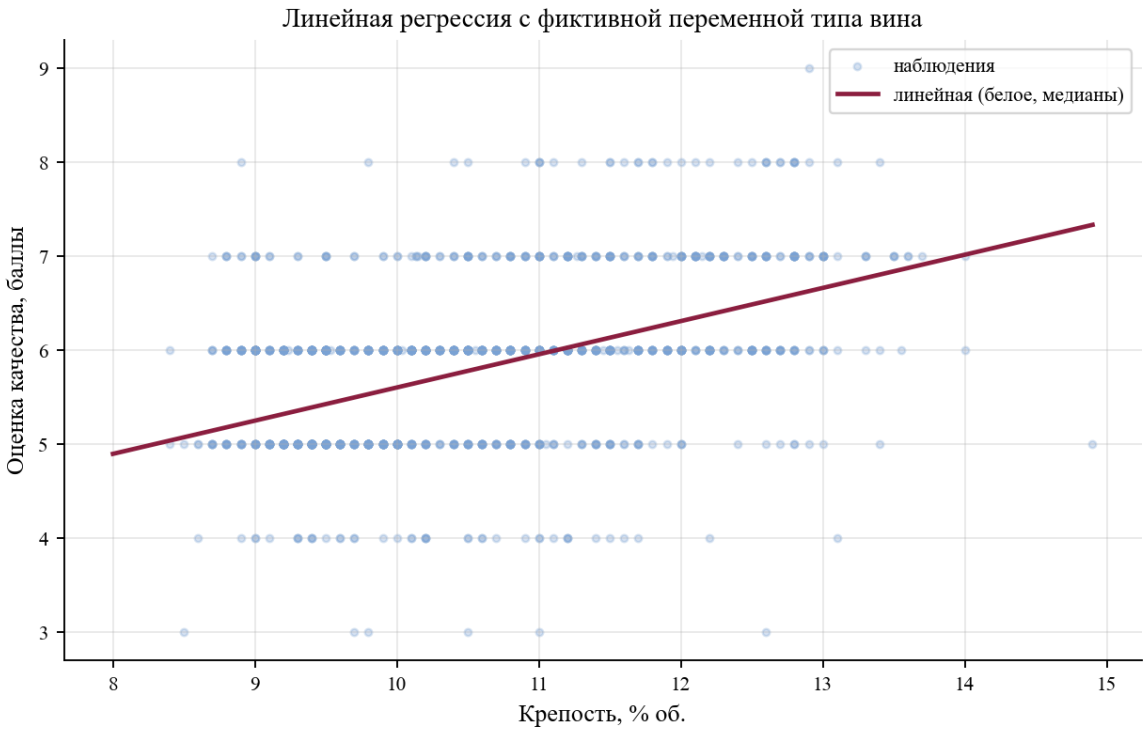


Рисунок 12 – Линейная регрессия (срез по белому вину при медианных контролях)

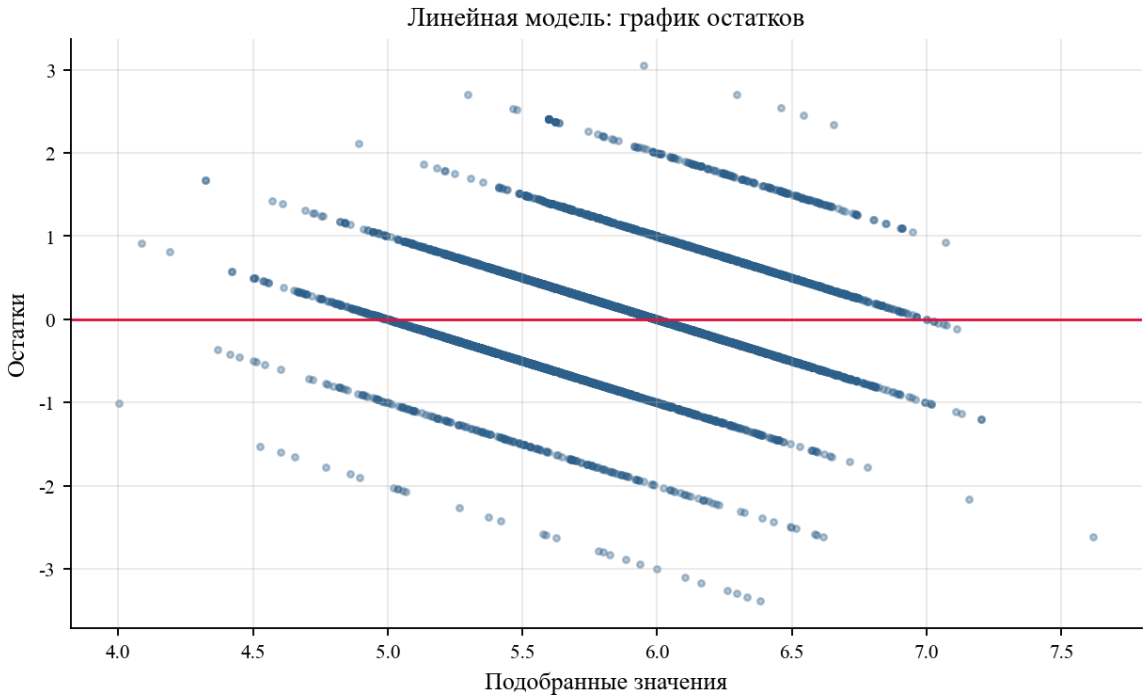


Рисунок 13 – График остатков линейной модели

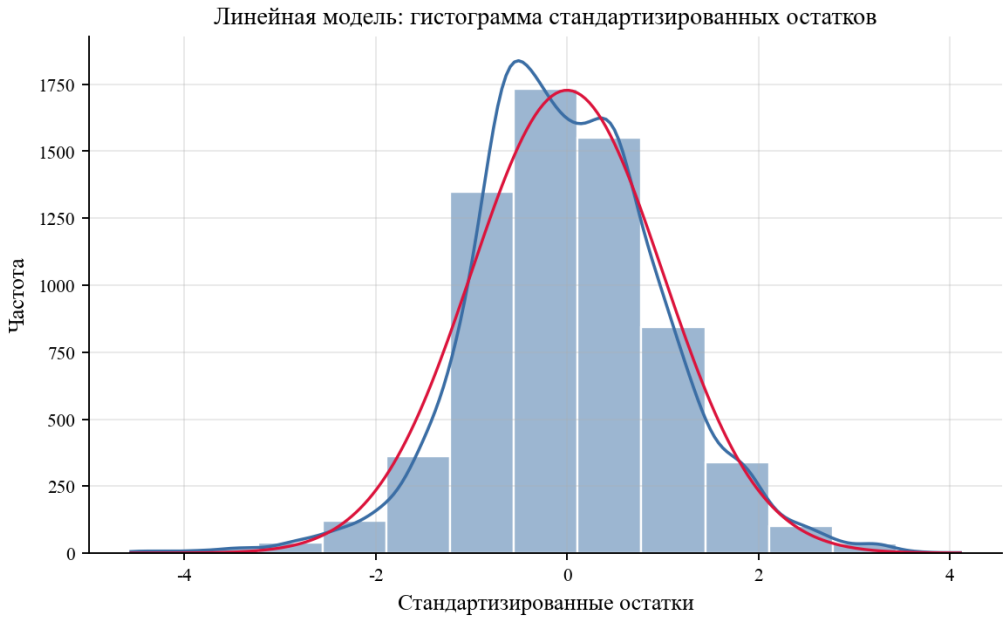


Рисунок 14 – Гистограмма стандартизированных остатков линейной модели

Диагностика. Среднее остатков близко к нулю (постоянство среднего выполняется в среднем). На графике остатков видна горизонтальная полосчатость — следствие дискретного отклика, а не пропущенного тренда. Разброс по вертикали примерно однороден в центре диапазона подобранных значений, на краях наблюдений меньше. Гистограмма стандартизированных остатков колоколообразная, с лёгкой асимметрией; нормальность остатков выполняется лишь приближённо, что для большого n не мешает состоятельности МНК, но заставляет опираться на робастность t/F. Гетероскедастичность выражена умеренно. Качество модели посредственное: $R^2 \approx 0{,}28$ типичен для сенсорных оценок, но для точного прогноза баллов его недостаточно.

Пуассоновская регрессия

Пуассоновская GLM со связью $\ln(\mu) = x'\beta$ оценивалась методом максимального правдоподобия. Уравнение:

$$\ln(\mu) = 1.1993 + 0.0531 \cdot \text{Dкрасное} + 0.0598 \cdot \text{alcohol} - 0.3048 \cdot \text{volatile_acidity} + 0.0040 \cdot \text{residual_sugar}$$

Псевдо-R^2 Макфаддена = 0,0097 — очень низкий: относительно константы логарифм правдоподобия улучшается слабо. AIC = 24125,8, BIC = 24159,7, deviance = 618,1 при df = 6492. Отношение Pearson χ^2 / df ≈ 0,094 < 1 указывает на недодисперсию: выборочная дисперсия качества (0,76) заметно меньше среднего (5,82), тогда как у закона Пуассона E(Y) = Var(Y). Следовательно, пуассоновская спецификация здесь теоретически сомнительна, хотя знаки коэффициентов совпадают с линейной моделью и все предикторы значимы.

Коэффициент	Оценка	p-value
Свободный член	1,1993	$< 1 \cdot 10^{-16}$
Dкрасное	0,0531	0,0014
alcohol	0,0598	$< 1 \cdot 10^{-16}$
volatile acidity	-0,3048	5,71e-13
residual sugar	0,0040	0,0015

Таблица 7 – Коэффициенты пуассоновской модели

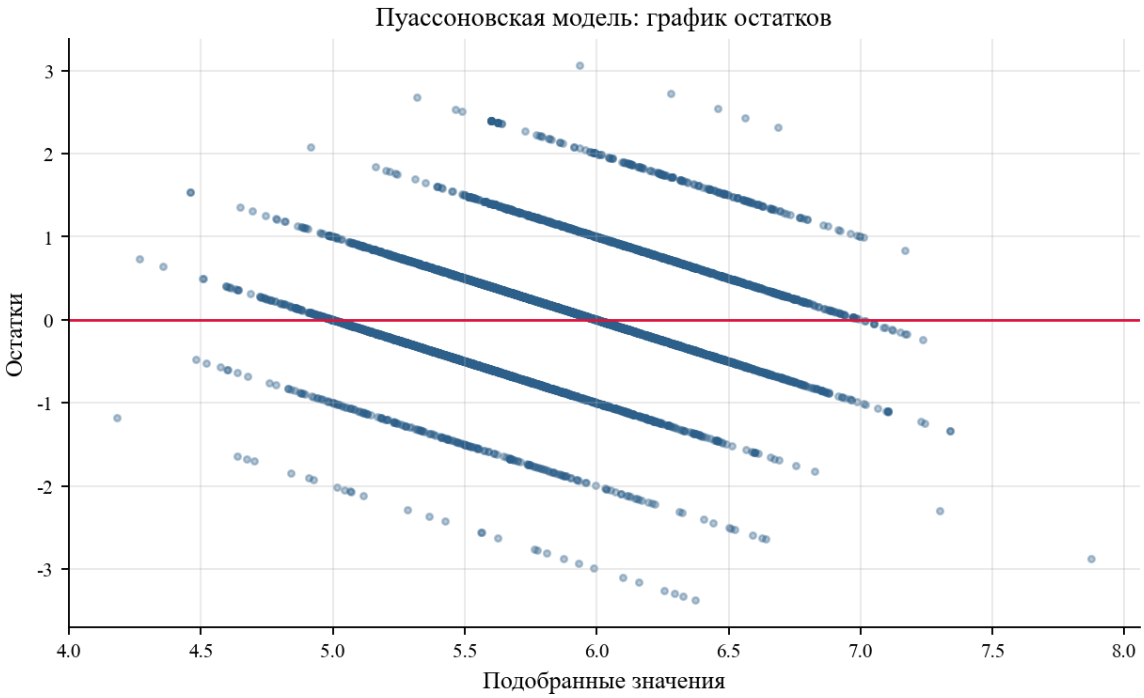


Рисунок 15 – Остатки пуассоновской модели

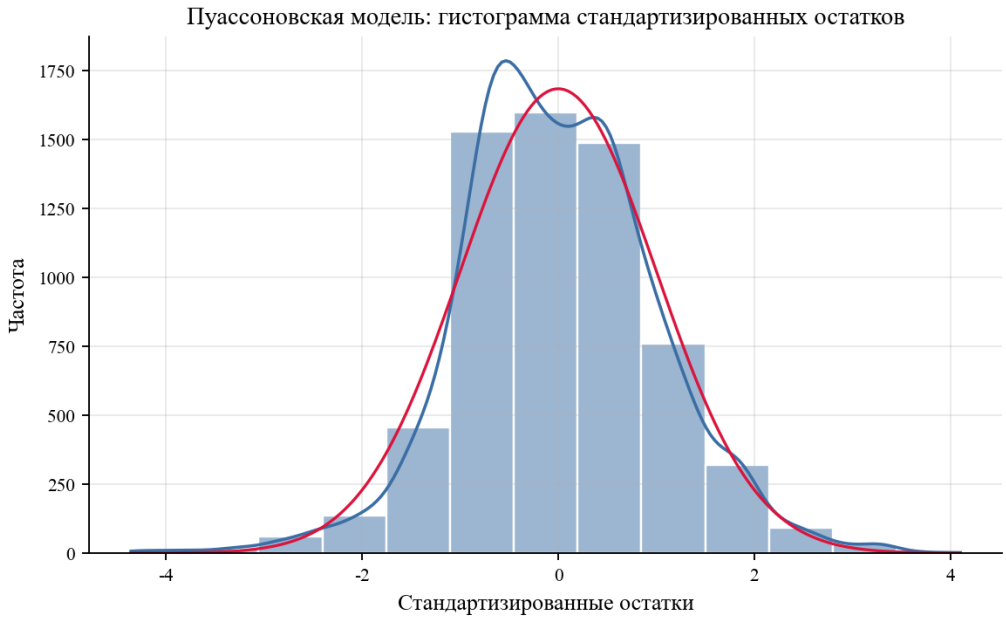


Рисунок 16 – Гистограмма стандартизированных остатков пуассоновской модели

RMSE пуассоновской модели (0,743) практически совпадает с линейной, но информационные критерии AIC/BIC существенно хуже (шкала правдоподобия иная, напрямую с OLS AIC несравнима; внутри GLM константная модель проигрывает, однако выигрыш мал). График остатков сохраняет дискретную структуру. Вывод: для данного отклика пуассоновская регрессия формально значима, но по качеству уступает линейной и плохо согласуется с дисперсией данных. Более адекватны порядковая логит-модель или линейная модель; пуассоновская включена по требованию задания и как иллюстрация выбора спецификации «по типу переменной».

Нелинейная модель

Нелинейная по факторам, линейная по параметрам свёртка (МНК):

$$\text{quality} = -5.0604 + 0.2407 \cdot D_{\text{красное}} + 15.9170 \cdot \text{alcohol} - 5.9794 \cdot \text{alcohol}^2 - 0.0990 \cdot \text{alcohol}^3 + 2.3840 \cdot \text{alcohol}^2 \cdot \ln(\text{alcohol}) - 1.7078 \cdot \text{volatile_acidity}$$

$R^2 = 0{,}274$, $R^2_{adj} = 0{,}274$, $F = 408{,}7$, $p < 1 \cdot 10^{-16}$ — модель в целом значима. RMSE = 0,744. Однако полиномиальные члены крепости по отдельности незначимы ($p > 0{,}38$): они линейно зависимы (мультиколлинеарность x, x^2, x^3, $x^2 \ln x$ на узком диапазоне 8–15 % об.). Значимы фиктивная переменная типа вина и летучая кислотность. По сравнению с линейной моделью R^2 даже чуть ниже (0,274 против 0,277), AIC выше — переусложнение не окупается.

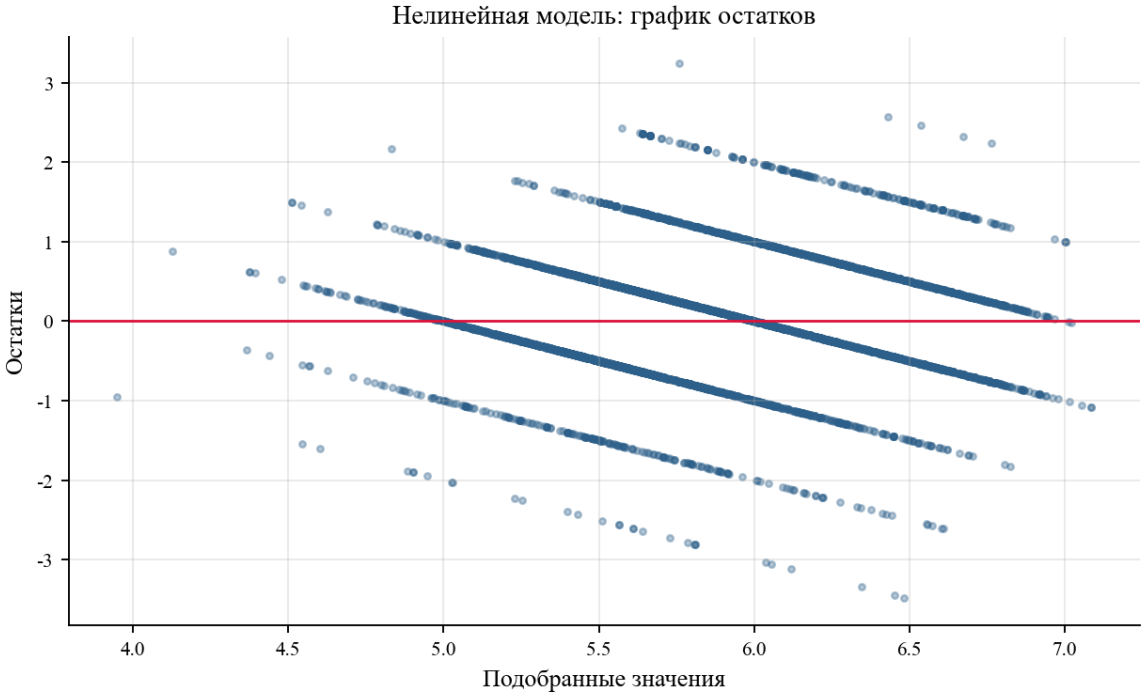


Рисунок 17 – Остатки нелинейной модели

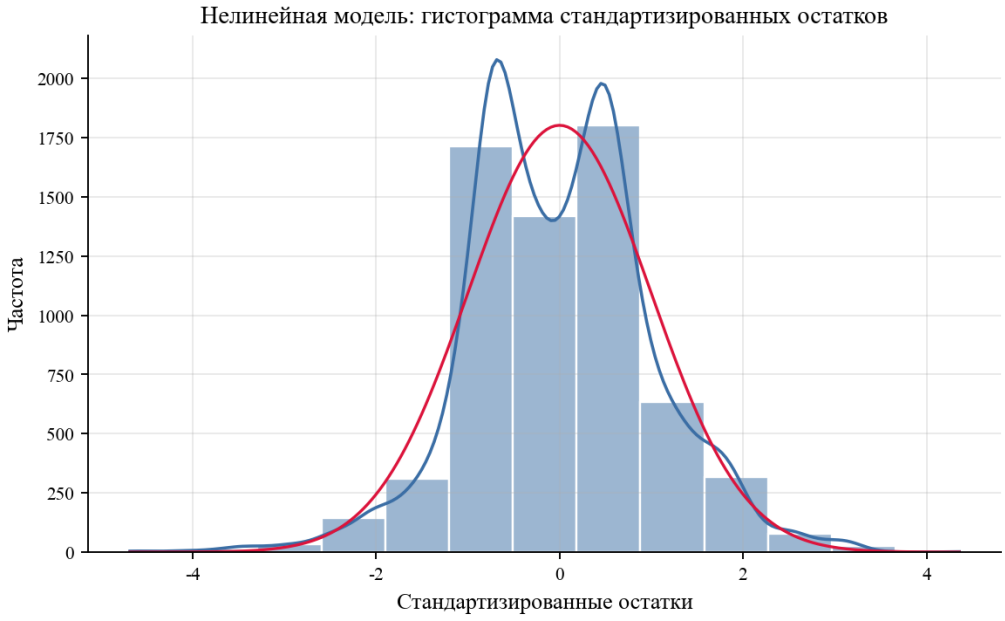


Рисунок 18 – Гистограмма стандартизированных остатков нелинейной модели

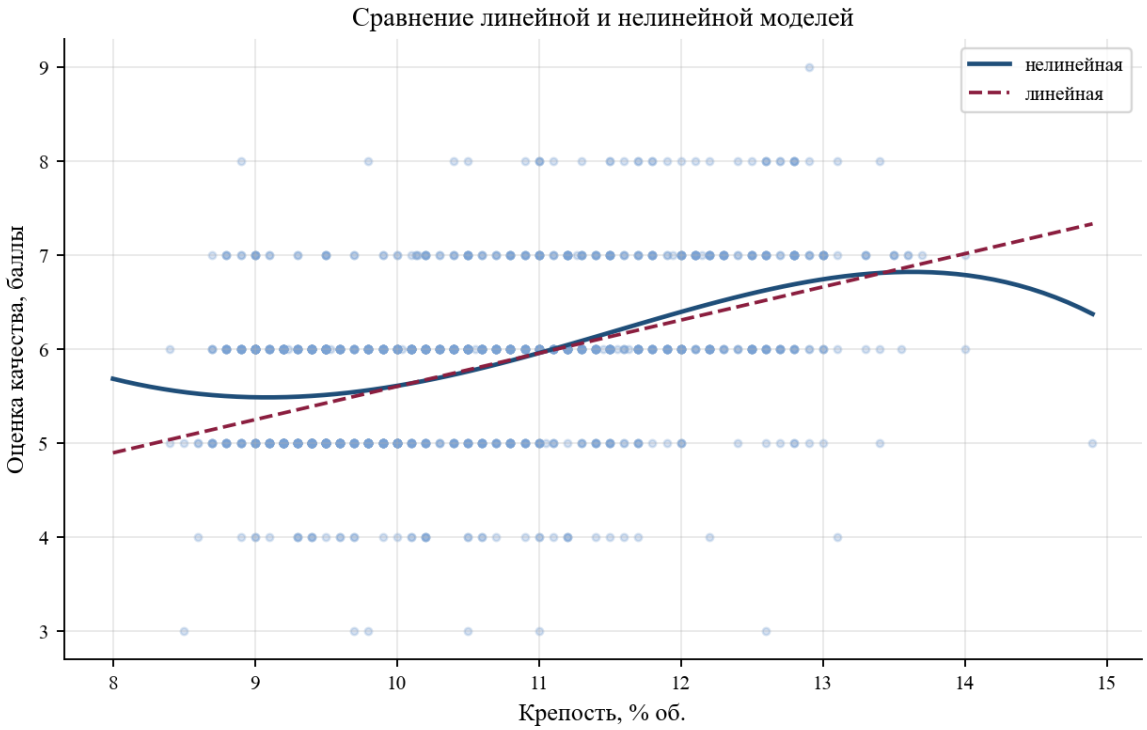


Рисунок 19 – Сравнение линейной и нелинейной подгонки по крепости

Сравнение моделей

Показатель	Линейная	Пуассон	Нелинейная
R^2 / pseudo-R^2	0,277	0,0097	0,274
R^2 скорр.	0,277	—	0,274
RMSE	0,742	0,743	0,744
MAE	0,580	0,580	0,589
AIC	14578,0	24125,8	14607,3
Значимость уравнения	да (F)	да (GLM)	да (F)
Значимость всех коэфф.	да	да	нет (полиномы)

Таблица 8 – Сравнительный анализ регрессионных моделей

Итог сравнения. Лучшей признана линейная модель с фиктивной переменной типа вина: она значима, все коэффициенты интерпретируемы и значимы, RMSE минимален, остатки без явного тренда. Нелинейная свёртка не улучшает подгонку из-за мультиколлинеарности на узком диапазоне крепости. Пуассоновская модель не соответствует дисперсии отклика. Качество даже лучшей модели умеренное: сенсорная оценка зависит от множества неучтённых факторов (сорт, выдержка, эксперт). Для практики достаточно линейной спецификации quality ~ alcohol + volatile acidity + residual sugar + Dкрасное.

Лабораторная работа 1.3. Дисперсионный анализ

Правила и условия применения

Дисперсионный анализ проверяет равенство средних зависимой переменной в нескольких группах, задаваемых градациями фактора. Классический ANOVA (критерий Фишера) предполагает: (1) независимость наблюдений; (2) нормальность признака внутри групп; (3) однородность дисперсий (гомоскедастичность, проверяется критерием Левена: отношение крайних дисперсий не должно быть слишком велико); (4) не менее двух градаций фактора; (5) желательно $\geq$ 20 наблюдений в клетке. При нарушении нормальности и/или сильной неоднородности дисперсий, особенно при несбалансированных группах, применяют непараметрический критерий Краскела–Уоллиса (сравнение распределений/средних рангов). Двухфакторный ANOVA дополнительно позволяет оценить взаимодействие факторов.

В нашей задаче наблюдения можно считать независимыми (разные партии вина). Нормальность крепости отвергнута, поэтому ANOVA интерпретируется с оглядкой на большой n (устойчивость F-критерия) и дублируется критерием Краскела–Уоллиса.

Формулировка гипотез и градации фактора

Зависимая переменная — крепость alcohol. Фактор — оценка качества, переведённая в три градации (числовая шкала 3–9 неудобна: клетки 3 и 9 малочисленны). Разбиение аргументировано предметно: 3–4 — низкое качество, 5–6 — типичное среднее, 7–9 — высокое. Объёмы групп: 246 / 4974 / 1277.

Градация фактора	n	Средняя крепость	Ст. откл.	Медиана
низкое (3–4)	246	10,184	0,999	10,050
среднее (5–6)	4974	10,265	1,071	10,000
высокое (7–9)	1277	11,433	1,216	11,500

Таблица 9 – Описательные статистики крепости по градациям качества

H_0 (однофакторный ANOVA / Краскел–Уоллис): средние (распределения) крепости в трёх группах качества совпадают, то есть качество не связано с уровнем алкоголя. H_1: хотя бы одна группа отличается. Уровень значимости $\alpha = 0{,}05$. H_0 отвергается, если $F > F_{крит}$ (или $H > \chi^2_{крит}$ для Краскела–Уоллиса), эквивалентно $p < 0{,}05$.

Однофакторный ANOVA

Критерий Левена: W = 19,11, p = 5,31e-09 — гипотеза однородности дисперсий отвергается. Это ещё один аргумент в пользу непараметрического критерия; F-тест при большом n всё же приводим.

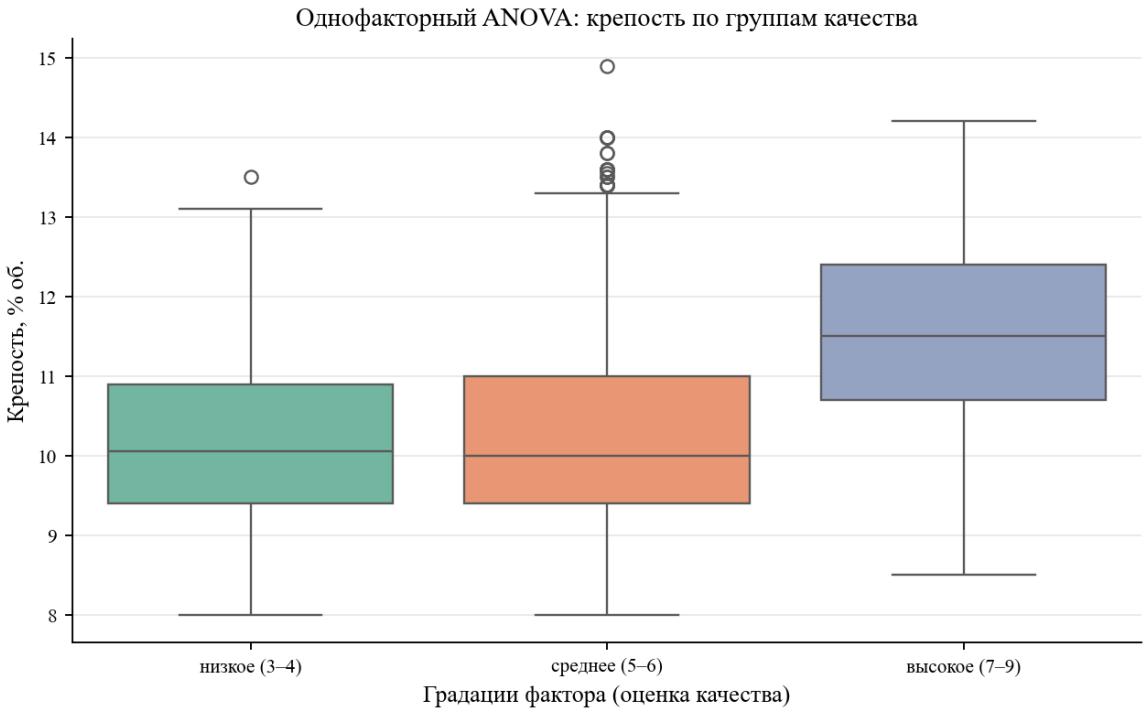


Рисунок 20 – Крепость по градациям качества (ящики с усами)

Однофакторный ANOVA: $F = 584{,}93$ при $df_1 = 2$, $df_2 = 6494$, $p = < 1 \cdot 10^{-16}$. Междугрупповая сумма квадратов 1410,6, остаточная 7830,4. Нулевая гипотеза уверенно отвергается: средняя крепость зависит от группы качества. По таблице 9 высокое качество заметно крепче (11,43 % об.) среднего и низкого (10,27 и 10,18 % об.).

Группа 1	Группа 2	Разность средних	p-adj	H_0 отвергнута
высокое (7–9)	низкое (3–4)	-1,249	$< 1 \cdot 10^{-16}$	да
высокое (7–9)	среднее (5–6)	-1,168	$< 1 \cdot 10^{-16}$	да
низкое (3–4)	среднее (5–6)	0,081	0,4966	нет

Таблица 10 – Апостериорные сравнения Тьюки HSD

Тест Тьюки показывает, что высокое качество отличается и от низкого, и от среднего (p-adj < 0,001), тогда как низкое и среднее между собой не различаются (p-adj ≈ 0,50). Эффект локализован в верхней части шкалы качества.

Критерий Краскела–Уоллиса

$H = 861{,}08$, $df = 2$, $p = < 1 \cdot 10^{-16}$. Непараметрический критерий, не требующий нормальности, также отвергает H_0. Вывод устойчив к выбору метода: группа качества связана с распределением крепости. Это согласуется с корреляционным анализом (положительная связь alcohol–quality) и с регрессией.

Двухфакторный дисперсионный анализ

Дополнительное задание. Фактор A — группа качества (3 уровня), фактор B — тип вина (2 уровня). Модель: alcohol ~ A + B + A×B. Гипотезы: H_0A — нет эффекта качества; H_0B — нет эффекта типа; H_0AB — нет взаимодействия.

Источник	SS	df	F	p

Качество (A)	1400,56	2	580,66	$< 1 \cdot 10^{-16}$
Тип вина (B)	0,012	1	0,010	0,9203
Взаимодействие A×B	2,230	2	0,925	0,3967
Остаток	7828,13	6491	—	—

Таблица 11 – Двухфакторный дисперсионный анализ

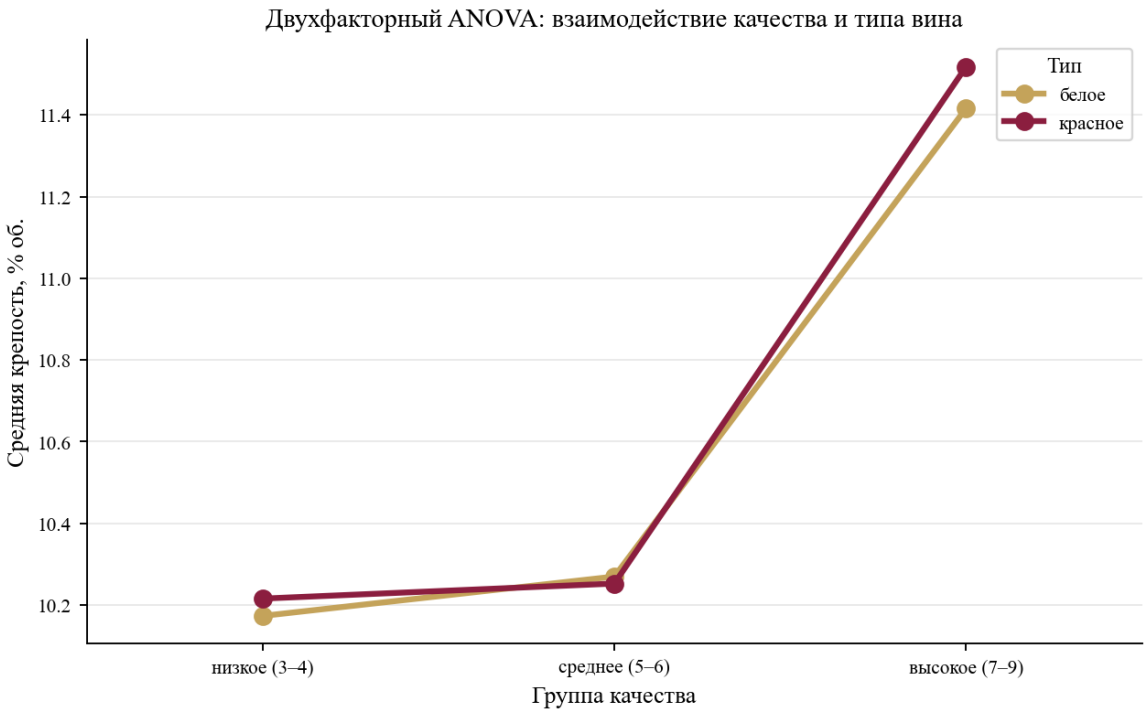


Рисунок 21 – Профиль средних: взаимодействие качества и типа вина

Эффект качества сохраняется ($F = 580{,}7$, $p < 1 \cdot 10^{-16}$). Эффект типа вина незначим ($p = 0{,}9203$): средняя крепость красного и белого почти одинакова. Взаимодействие незначимо ($p = 0{,}3967$): линии профилей почти параллельны, рост крепости в группе высокого качества наблюдается у обоих типов. Таким образом, связь «качество — крепость» не специфична для цвета вина.

Заключение

1. Выборки крепости, кислотности, сахара и качества не согласуются с нормальным законом (Шапиро–Уилк, Д’Агостино, Лиллиефорс, Q–Q, гистограммы Стерджесса, асимметрия/эксцесс). Для связей использован ранговый анализ, для групп — ANOVA совместно с критерием Краскела–Уоллиса.

2. Тип вина и оценка качества зависимы по χ^2, но сила связи слабая ($V \approx 0{,}13$). Наиболее сильная значимая корреляция — между крепостью и качеством ($\rho \approx 0{,}45$, умеренная); кислотность связана с качеством слабо отрицательно; сахар с качеством практически не связан.

3. Пример с tylervigen.com демонстрирует ложную корреляцию: $r = 0{,}947$ у исходных рядов падает до незначимых 0,27 после удаления трендов. Причина — общая временна́я динамика, а не причинность.

4. Среди регрессионных моделей предпочтительна линейная с фиктивной переменной типа вина ($R^2 \approx 0{,}28$, все коэффициенты значимы). Пуассоновская модель плохо согласуется с недодисперсией баллов, нелинейная свёртка не улучшает подгонку.

5. Однофакторный ANOVA и критерий Краскела–Уоллиса отвергают равенство средней крепости по группам качества; отличие даёт группа высоких баллов. Двухфакторный анализ: значим только фактор качества, тип вина и взаимодействие незначимы.

Код программы

```
from __future__ import annotations


import json
import math
import warnings
from pathlib import Path


import matplotlib


matplotlib.use("Agg")
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
import statsmodels.api as sm
import statsmodels.formula.api as smf
from scipy import stats
from statsmodels.stats.anova import anova_lm
from statsmodels.stats.diagnostic import lilliefors
from statsmodels.stats.multicomp import pairwise_tukeyhsd
from statsmodels.stats.outliers_influence import OLSInfluence


warnings.filterwarnings("ignore", category=FutureWarning)
warnings.filterwarnings("ignore", category=UserWarning)


BASE = Path(__file__).resolve().parent
DATA = BASE / "data"
FIG = BASE / "figures"
FIG.mkdir(exist_ok=True)


ALPHA = 0.05
SEED = 42
rng = np.random.default_rng(SEED)


plt.rcParams.update(
    {
        "font.family": "Times New Roman",
        "axes.unicode_minus": False,
        "figure.dpi": 140,
        "savefig.dpi": 170,
        "axes.grid": True,
        "grid.alpha": 0.28,
        "axes.spines.top": False,
        "axes.spines.right": False,
        "figure.facecolor": "white",
        "axes.facecolor": "white",
        "axes.labelsize": 11,
        "axes.titlesize": 12,
        "legend.fontsize": 9,
        "xtick.labelsize": 9,
        "ytick.labelsize": 9,
    }
)


LABELS = {
    "alcohol": "Крепость, % об.",
    "volatile acidity": "Летучая кислотность, г/дм³",
    "residual sugar": "Остаточный сахар, г/дм³",
    "quality": "Оценка качества, баллы",
    "sulphates": "Сульфаты, г/дм³",
    "type": "Тип вина",
}


CHADDOCK = [
    (0.3, "слабая"),
    (0.5, "умеренная"),
    (0.7, "заметная"),
    (0.9, "высокая"),
    (0.99, "весьма высокая"),
    (1.01, "функциональная"),
]
```

```
def chaddock(r: float) -> str:
    a = abs(r)
    if a < 0.1:
        return "практически отсутствует"
    for thr, name in CHADDOCK:
        if a < thr:
            return name
    return "функциональная"



def to_py(x):
    if isinstance(x, dict):
        return {str(k): to_py(v) for k, v in x.items()}
    if isinstance(x, (list, tuple)):
        return [to_py(v) for v in x]
    if isinstance(x, (np.floating, np.integer)):
        return x.item()
    if isinstance(x, float) and (math.isnan(x) or math.isinf(x)):
        return None
    if hasattr(x, "item"):
        try:
            return x.item()
        except Exception:
            return str(x)
    return x



def fmt_p(p: float) -> str:
    if p is None or (isinstance(p, float) and math.isnan(p)):
        return "—"
    if p < 1e-16:
        return "< 1e-16"
    if p < 1e-4:
        return f"{p:.2e}"
    return f"{p:.4f}"



def savefig(name: str) -> str:
    path = FIG / name
    plt.tight_layout()
    plt.savefig(path, bbox_inches="tight")
    plt.close()
    return str(path)



def load_wine() -> pd.DataFrame:
    red = pd.read_csv(DATA / "winequality-red.csv", sep=";")
    white = pd.read_csv(DATA / "winequality-white.csv", sep=";")
    red["type"] = "красное"
    white["type"] = "белое"
    df = pd.concat([red, white], ignore_index=True)
    df.columns = [c.strip() for c in df.columns]
    df["quality_group"] = pd.cut(
        df["quality"],
        bins=[0, 4, 6, 10],
        labels=["низкое (3-4)", "среднее (5-6)", "высокое (7-9)"],
        right=True,
    )
    df["sugar_group"] = pd.cut(
        df["residual sugar"],
        bins=[-0.01, 4.0, 12.0, 100],
        labels=["сухое (≤4 г/дм³)", "полусухое (4-12)", "сладкое (>12)"],
        right=True,
    )
    df["alcohol_group"] = pd.qcut(
        df["alcohol"],
        q=3,
        labels=["низкая крепость", "средняя крепость", "высокая крепость"],
    )
    df["type_white"] = (df["type"] == "белое").astype(int)
    return df
```

```
def descriptive(series: pd.Series) -> dict:
    x = series.dropna().astype(float)
    mode = x.mode(dropna=True)
    return {
        "n": int(x.size),
        "mean": float(x.mean()),
        "median": float(x.median()),
        "mode": float(mode.iloc[0]) if len(mode) else None,
        "std": float(x.std(ddof=1)),
        "var": float(x.var(ddof=1)),
        "min": float(x.min()),
        "max": float(x.max()),
        "q1": float(x.quantile(0.25)),
        "q3": float(x.quantile(0.75)),
        "skew": float(stats.skew(x, bias=False)),
        "kurtosis_excess": float(stats.kurtosis(x, fisher=True, bias=False)),
        "kurtosis_pearson": float(stats.kurtosis(x, fisher=False, bias=False)),
    }



def normality(series: pd.Series) -> dict:
    x = series.dropna().astype(float).to_numpy()
    n = len(x)
    sample = x if n <= 5000 else rng.choice(x, size=5000, replace=False)
    shapiro = stats.shapiro(sample)
    dagostino = stats.normaltest(x)
    try:
        lf_stat, lf_p = lilliefors(x, dist="norm")
    except Exception:
        lf_stat, lf_p = float("nan"), float("nan")
    z = (x - x.mean()) / x.std(ddof=1)
    ks = stats.kstest(z, "norm")
    return {
        "shapiro_stat": float(shapiro.statistic),
        "shapiro_p": float(shapiro.pvalue),
        "shapiro_n": int(len(sample)),
        "dagostino_stat": float(dagostino.statistic),
        "dagostino_p": float(dagostino.pvalue),
        "lilliefors_stat": float(lf_stat),
        "lilliefors_p": float(lf_p),
        "ks_stat": float(ks.statistic),
        "ks_p": float(ks.pvalue),
        "is_normal": bool(dagostino.pvalue >= ALPHA and shapiro.pvalue >= ALPHA),
    }



def sturges_bins(n: int) -> int:
    return max(5, int(math.floor(1 + 3.322 * math.log10(n))))



def corr_with_p(x: pd.Series, y: pd.Series, method: str) -> dict:
    a = pd.concat([x, y], axis=1).dropna()
    u, v = a.iloc[:, 0], a.iloc[:, 1]
    if method == "pearson":
        r, p = stats.pearsonr(u, v)
    elif method == "spearman":
        r, p = stats.spearmanr(u, v)
    else:
        r, p = stats.kendalltau(u, v)
    n = len(u)
    t_stat = r * math.sqrt(max(n - 2, 1)) / math.sqrt(max(1e-12, 1 - r**2))
    t_crit = stats.t.ppf(1 - ALPHA / 2, df=n - 2)
    r_crit = t_crit * math.sqrt((1 - r**2) / (n - 2)) if n > 2 else float("nan")
    return {
        "r": float(r),
        "p": float(p),
        "n": int(n),
        "t": float(t_stat),
        "t_crit": float(t_crit),
        "r_crit": float(r_crit),
        "significant": bool(p < ALPHA),
        "chaddock": chaddock(r),
    }



def model_metrics(resid: np.ndarray, y: np.ndarray) -> dict:
```

```
    sse = float(np.sum(resid**2))
    sst = float(np.sum((y - y.mean()) ** 2))
    n = len(y)
    rmse = float(np.sqrt(sse / n))
    mae = float(np.mean(np.abs(resid)))
    return {"rmse": rmse, "mae": mae, "sse": sse, "sst": sst}



def standardized_residuals(resid: np.ndarray) -> np.ndarray:
    s = resid.std(ddof=1)
    return resid / s if s else resid



def extract_ols(model) -> dict:
    params = {k: float(v) for k, v in model.params.items()}
    pvalues = {k: float(v) for k, v in model.pvalues.items()}
    bse = {k: float(v) for k, v in model.bse.items()}
    tvalues = {k: float(v) for k, v in model.tvalues.items()}
    return {
        "params": params,
        "pvalues": pvalues,
        "bse": bse,
        "tvalues": tvalues,
        "rsquared": float(model.rsquared),
        "rsquared_adj": float(model.rsquared_adj),
        "fvalue": float(model.fvalue),
        "f_pvalue": float(model.f_pvalue),
        "n": int(model.nobs),
        "df_model": float(model.df_model),
        "df_resid": float(model.df_resid),
        "aic": float(model.aic),
        "bic": float(model.bic),
        "equation": format_equation(params),
    }



def format_equation(params: dict, y_name: str = "quality") -> str:
    parts = [f"{y_name} ="]
    first = True
    for name, val in params.items():
        if name == "Intercept":
            parts.append(f"{val:.4f}")
            first = False
            continue
        sign = " + " if val >= 0 else " - "
        if first:
            sign = "" if val >= 0 else "-"
            first = False
        nice = (
            name.replace("C(type)[T.красное]", "тип_красное")
            .replace("I(alcohol ** 2)", "alcohol²")
            .replace("I(alcohol ** 3)", "alcohol³")
            .replace("I(alcohol ** 2 * np.log(alcohol))", "alcohol²·ln(alcohol)")
            .replace("Q('volatile acidity')", "volatile_acidity")
            .replace("Q('residual sugar')", "residual_sugar")
        )
        parts.append(f"{sign}{abs(val):.4f}·{nice}")
    return "".join(parts)



def plot_qq(df: pd.DataFrame, cols: list[str], name: str):
    fig, axes = plt.subplots(2, 2, figsize=(8.6, 7.4))
    for ax, col in zip(axes.ravel(), cols):
        stats.probplot(df[col].dropna(), dist="norm", plot=ax)
        ax.set_title(LABELS.get(col, col))
        ax.set_xlabel("Теоретические квантили")
        ax.set_ylabel("Выборочные квантили")
    fig.suptitle("Графики квантилей (Q-Q) для выбранных признаков", fontsize=13)
    savefig(name)



def plot_hists(df: pd.DataFrame, cols: list[str], name: str):
    n = len(df)
    k = sturges_bins(n)
    fig, axes = plt.subplots(2, 2, figsize=(8.8, 7.4))
```

```
    for ax, col in zip(axes.ravel(), cols):
        x = df[col].dropna()
        h = (x.max() - x.min()) / k
        sns.histplot(x, bins=k, kde=True, ax=ax, color="#3b6ea5", edgecolor="white")
        ax.set_title(f"{LABELS.get(col, col)}\nk = {k}, h ≈ {h:.3f}")
        ax.set_xlabel(LABELS.get(col, col))
        ax.set_ylabel("Частота")
    fig.suptitle("Гистограммы (число интервалов по формуле Стерджесса)", fontsize=13)
    savefig(name)


def plot_boxes(df: pd.DataFrame, cols: list[str], name: str):
    fig, axes = plt.subplots(1, len(cols), figsize=(10.5, 4.2))
    for ax, col in zip(axes, cols):
        sns.boxplot(y=df[col], ax=ax, color="#7aa2d4", fliersize=2)
        ax.set_ylabel(LABELS.get(col, col))
        ax.set_title(LABELS.get(col, col))
    fig.suptitle("Ящики с усами", fontsize=13)
    savefig(name)


def plot_contingency(table: pd.DataFrame, name: str, title: str):
    fig, ax = plt.subplots(figsize=(8.2, 4.6))
    sns.heatmap(table, annot=True, fmt="d", cmap="YlGnBu", ax=ax, cbar=False)
    ax.set_title(title)
    ax.set_ylabel("Тип вина")
    ax.set_xlabel("Оценка качества")
    savefig(name)


def plot_corr_heat(mat: pd.DataFrame, name: str, title: str):
    fig, ax = plt.subplots(figsize=(6.6, 5.4))
    sns.heatmap(
        mat,
        annot=True,
        fmt=".3f",
        cmap="RdBu_r",
        vmin=-1,
        vmax=1,
        ax=ax,
        square=True,
    )
    ax.set_title(title)
    savefig(name)


def plot_scatter(df: pd.DataFrame, name: str):
    fig, ax = plt.subplots(figsize=(7.6, 5.2))
    sample = df.sample(n=min(1500, len(df)), random_state=SEED)
    sns.scatterplot(
        data=sample,
        x="alcohol",
        y="quality",
        hue="type",
        alpha=0.45,
        ax=ax,
        palette={"красное": "#8b1e3f", "белое": "#c4a35a"},
    )
    sns.regplot(
        data=df,
        x="alcohol",
        y="quality",
        scatter=False,
        ax=ax,
        color="#1f4e79",
        line_kws={"linewidth": 2},
    )
    ax.set_xlabel(LABELS["alcohol"])
    ax.set_ylabel(LABELS["quality"])
    ax.set_title("Диаграмма рассеяния: крепость и оценка качества")
    ax.legend(title="Тип вина")
    savefig(name)


def plot_residuals(fitted, resid, std_resid, title_prefix: str, name_res: str, name_hist: str):
```

```
    fig, ax = plt.subplots(figsize=(7.4, 4.6))
    ax.scatter(fitted, resid, s=8, alpha=0.35, color="#2c5f8a")
    ax.axhline(0, color="crimson", lw=1.2)
    ax.set_xlabel("Подобранные значения")
    ax.set_ylabel("Остатки")
    ax.set_title(f"{title_prefix}: график остатков")
    savefig(name_res)

    k = sturges_bins(len(std_resid))
    fig, ax = plt.subplots(figsize=(7.0, 4.4))
    sns.histplot(std_resid, bins=k, kde=True, ax=ax, color="#3b6ea5", edgecolor="white")
    xs = np.linspace(min(std_resid), max(std_resid), 200)
    ax.plot(xs, stats.norm.pdf(xs) * len(std_resid) * (xs.max() - xs.min()) / k, color="crimson",
lw=1.4)
    ax.set_xlabel("Стандартизированные остатки")
    ax.set_ylabel("Частота")
    ax.set_title(f"{title_prefix}: гистограмма стандартизированных остатков")
    savefig(name_hist)



def run_spurious() -> dict:
    sp = pd.read_csv(DATA / "spurious.csv")
    x = np.arange(1, len(sp) + 1, dtype=float)
    y1 = sp["cheese_lb"].to_numpy(float)
    y2 = sp["bedsheet_deaths"].to_numpy(float)

    r_raw, p_raw = stats.pearsonr(y1, y2)
    c1 = np.polyfit(x, y1, 1)
    c2 = np.polyfit(x, y2, 2)
    y1_hat = np.polyval(c1, x)
    y2_hat = np.polyval(c2, x)
    e1 = y1 - y1_hat
    e2 = y2 - y2_hat
    e1s = standardized_residuals(e1)
    e2s = standardized_residuals(e2)
    r_res, p_res = stats.pearsonr(e1, e2)
    n = len(x)
    t_raw = r_raw * math.sqrt(n - 2) / math.sqrt(1 - r_raw**2)
    t_res = r_res * math.sqrt(n - 2) / math.sqrt(max(1e-12, 1 - r_res**2))
    t_crit = stats.t.ppf(1 - ALPHA / 2, n - 2)

    fig, ax1 = plt.subplots(figsize=(8.2, 4.8))
    ax2 = ax1.twinx()
    ax1.plot(sp["year"], y1, "o-", color="#1f4e79", label="Потребление сыра")
    ax2.plot(sp["year"], y2, "s--", color="#8b1e3f", label="Смерти (простыни)")
    ax1.set_xlabel("Год")
    ax1.set_ylabel("Сыр, фунты на человека", color="#1f4e79")
    ax2.set_ylabel("Число смертей", color="#8b1e3f")
    ax1.set_title("Ложная корреляция: сыр и смерти от запутывания в простынях")
    lines = ax1.get_lines() + ax2.get_lines()
    labels = [ln.get_label() for ln in lines]
    ax1.legend(lines, labels, loc="upper left")
    ax2.spines["right"].set_visible(True)
    savefig("spurious_raw.png")

    fig, axes = plt.subplots(1, 2, figsize=(9.2, 4.2))
    axes[0].scatter(x, y1, color="#1f4e79")
    axes[0].plot(x, y1_hat, color="crimson")
    axes[0].set_title("Сыр: линейный тренд")
    axes[0].set_xlabel("Отсчёт года")
    eq1 = f"y = {c1[0]:.3f}t + {c1[1]:.3f}"
    axes[0].text(0.05, 0.9, eq1, transform=axes[0].transAxes)
    axes[1].scatter(x, y2, color="#8b1e3f")
    axes[1].plot(x, y2_hat, color="crimson")
    axes[1].set_title("Смерти: квадратичный тренд")
    axes[1].set_xlabel("Отсчёт года")
    eq2 = f"y = {c2[0]:.3f}t² + {c2[1]:.3f}t + {c2[2]:.2f}"
    axes[1].text(0.05, 0.9, eq2, transform=axes[1].transAxes, fontsize=8)
    savefig("spurious_trends.png")

    fig, ax = plt.subplots(figsize=(7.4, 4.4))
    ax.plot(sp["year"], e1, "o-", label="Остатки (сыр)")
    ax.plot(sp["year"], e2, "s--", label="Остатки (смерти)")
    ax.axhline(0, color="gray", lw=1)
    ax.set_xlabel("Год")
    ax.set_ylabel("Остаток")
```

```
    ax.set_title("Остатки после удаления трендов")
    ax.legend()
    savefig("spurious_resid.png")

    fig, axes = plt.subplots(1, 2, figsize=(8.8, 4.0))
    k = sturges_bins(n)
    sns.histplot(e1s, bins=max(4, k - 3), kde=True, ax=axes[0], color="#3b6ea5")
    sns.histplot(e2s, bins=max(4, k - 3), kde=True, ax=axes[1], color="#8b1e3f")
    axes[0].set_title("Станд. остатки: сыр")
    axes[1].set_title("Станд. остатки: смерти")
    savefig("spurious_std_hist.png")

    return {
        "years": sp["year"].tolist(),
        "cheese": y1.tolist(),
        "deaths": y2.tolist(),
        "r_raw": float(r_raw),
        "p_raw": float(p_raw),
        "t_raw": float(t_raw),
        "r_resid": float(r_res),
        "p_resid": float(p_res),
        "t_resid": float(t_res),
        "t_crit": float(t_crit),
        "n": int(n),
        "eq_cheese": eq1,
        "eq_deaths": eq2,
        "coef_cheese": [float(v) for v in c1],
        "coef_deaths": [float(v) for v in c2],
        "y1_hat": y1_hat.tolist(),
        "y2_hat": y2_hat.tolist(),
        "e1": e1.tolist(),
        "e2": e2.tolist(),
        "e1s": e1s.tolist(),
        "e2s": e2s.tolist(),
        "chaddock_raw": chaddock(r_raw),
        "chaddock_resid": chaddock(r_res),
        "significant_raw": bool(p_raw < ALPHA),
        "significant_resid": bool(p_res < ALPHA),
    }



def main() -> dict:
    df = load_wine()
    num_cols = ["alcohol", "volatile acidity", "residual sugar", "quality"]
    desc = {c: descriptive(df[c]) for c in num_cols}
    norm = {c: normality(df[c]) for c in num_cols}

    plot_qq(df, num_cols, "qq_plots.png")
    plot_hists(df, num_cols, "hist_sturges.png")
    plot_boxes(df, num_cols, "boxplots.png")

    ct = pd.crosstab(df["type"], df["quality"])
    chi2 = stats.chi2_contingency(ct)
    n = ct.values.sum()
    cramer = math.sqrt(chi2.statistic / (n * (min(ct.shape) - 1)))
    plot_contingency(ct, "contingency.png", "Таблица сопряжённости: тип вина × оценка качества")

    expected = pd.DataFrame(chi2.expected_freq, index=ct.index, columns=ct.columns)

    pearson = df[num_cols].corr(method="pearson")
    spearman = df[num_cols].corr(method="spearman")
    kendall = df[num_cols].corr(method="kendall")
    plot_corr_heat(pearson, "corr_pearson.png", "Корреляция Пирсона")
    plot_corr_heat(spearman, "corr_spearman.png", "Корреляция Спирмена")
    plot_scatter(df, "scatter_alcohol_quality.png")

    pairs = [
        ("alcohol", "quality"),
        ("volatile acidity", "quality"),
        ("residual sugar", "quality"),
        ("alcohol", "volatile acidity"),
        ("alcohol", "residual sugar"),
        ("volatile acidity", "residual sugar"),
    ]
    corr_tests = {}
```

```
    for a, b in pairs:
        corr_tests[f"{a}__{b}"] = {
            "pearson": corr_with_p(df[a], df[b], "pearson"),
            "spearman": corr_with_p(df[a], df[b], "spearman"),
            "kendall": corr_with_p(df[a], df[b], "kendall"),
        }

    spurious = run_spurious()

    dreg = df[["quality", "alcohol", "volatile acidity", "residual sugar", "type"]].dropna()
    lin = smf.ols(
        "quality ~ alcohol + Q('volatile acidity') + Q('residual sugar') + C(type)",
        data=dreg,
    ).fit()
    lin_info = extract_ols(lin)
    lin_resid = lin.resid.to_numpy()
    lin_fitted = lin.fittedvalues.to_numpy()
    lin_std = np.asarray(OLSInfluence(lin).resid_studentized_internal)
    lin_info["metrics"] = model_metrics(lin_resid, dreg["quality"].to_numpy())
    lin_info["resid_mean"] = float(lin_resid.mean())
    lin_info["resid_std"] = float(lin_resid.std(ddof=1))
    plot_residuals(
        lin_fitted,
        lin_resid,
        lin_std,
        "Линейная модель",
        "lin_resid.png",
        "lin_std_hist.png",
    )

    fig, ax = plt.subplots(figsize=(7.4, 4.8))
    sample = dreg.sample(n=min(1200, len(dreg)), random_state=SEED)
    ax.scatter(sample["alcohol"],    sample["quality"],    s=10,    alpha=0.3,    color="#7aa2d4",
label="наблюдения")
    grid = pd.DataFrame(
        {
            "alcohol": np.linspace(dreg["alcohol"].min(), dreg["alcohol"].max(), 80),
            "volatile acidity": dreg["volatile acidity"].median(),
            "residual sugar": dreg["residual sugar"].median(),
            "type": "белое",
        }
    )
    ax.plot(grid["alcohol"],  lin.predict(grid),  color="#8b1e3f",  lw=2,  label="линейная  (белое,
медианы)")
    ax.set_xlabel(LABELS["alcohol"])
    ax.set_ylabel(LABELS["quality"])
    ax.set_title("Линейная регрессия с фиктивной переменной типа вина")
    ax.legend()
    savefig("lin_fit.png")

    poi = smf.glm(
        "quality ~ alcohol + Q('volatile acidity') + Q('residual sugar') + C(type)",
        data=dreg,
        family=sm.families.Poisson(),
    ).fit()
    poi_params = {k: float(v) for k, v in poi.params.items()}
    poi_p = {k: float(v) for k, v in poi.pvalues.items()}
    y = dreg["quality"].to_numpy(float)
    mu = poi.fittedvalues.to_numpy()
    poi_resid = y - mu
    poi_std = poi.resid_pearson.to_numpy()
    null = smf.glm("quality ~ 1", data=dreg, family=sm.families.Poisson()).fit()
    mcfadden = 1 - float(poi.llf / null.llf)
    poi_info = {
        "params": poi_params,
        "pvalues": poi_p,
        "equation": format_equation(poi_params, "ln(μ)"),
        "aic": float(poi.aic),
        "bic": float(poi.bic),
        "deviance": float(poi.deviance),
        "pearson_chi2": float(poi.pearson_chi2),
        "df_resid": float(poi.df_resid),
        "llf": float(poi.llf),
        "mcfadden_r2": float(mcfadden),
        "metrics": model_metrics(poi_resid, y),
        "resid_mean": float(poi_resid.mean()),
        "resid_std": float(poi_resid.std(ddof=1)),
    }
```

```
    plot_residuals(
        mu,
        poi_resid,
        standardized_residuals(poi_std),
        "Пуассоновская модель",
        "poi_resid.png",
        "poi_std_hist.png",
    )

    nonlin = smf.ols(
        "quality ~ alcohol + I(alcohol ** 2) + I(alcohol ** 3) "
        "+ I(alcohol ** 2 * np.log(alcohol)) + Q('volatile acidity') + C(type)",
        data=dreg,
    ).fit()
    non_info = extract_ols(nonlin)
    non_resid = nonlin.resid.to_numpy()
    non_fitted = nonlin.fittedvalues.to_numpy()
    non_std = np.asarray(OLSInfluence(nonlin).resid_studentized_internal)
    non_info["metrics"] = model_metrics(non_resid, dreg["quality"].to_numpy())
    non_info["resid_mean"] = float(non_resid.mean())
    non_info["resid_std"] = float(non_resid.std(ddof=1))
    plot_residuals(
        non_fitted,
        non_resid,
        non_std,
        "Нелинейная модель",
        "nonlin_resid.png",
        "nonlin_std_hist.png",
    )

    fig, ax = plt.subplots(figsize=(7.4, 4.8))
    ax.scatter(sample["alcohol"], sample["quality"], s=10, alpha=0.3, color="#7aa2d4")
    ax.plot(grid["alcohol"], nonlin.predict(grid), color="#1f4e79", lw=2, label="нелинейная")
    ax.plot(grid["alcohol"],     lin.predict(grid),     color="#8b1e3f",     lw=1.6,     ls="--",
label="линейная")
    ax.set_xlabel(LABELS["alcohol"])
    ax.set_ylabel(LABELS["quality"])
    ax.set_title("Сравнение линейной и нелинейной моделей")
    ax.legend()
    savefig("models_compare.png")

    groups = [g["alcohol"].to_numpy() for _, g in df.groupby("quality_group", observed=True)]
    levene = stats.levene(*groups)
    anova_one = stats.f_oneway(*groups)
    kruskal = stats.kruskal(*groups)
    ols_aov = smf.ols("alcohol ~ C(quality_group)", data=df).fit()
    aov_table = anova_lm(ols_aov, typ=2)
    tukey = pairwise_tukeyhsd(df["alcohol"], df["quality_group"].astype(str), alpha=ALPHA)

    fig, ax = plt.subplots(figsize=(7.6, 4.8))
    sns.boxplot(
        data=df,
        x="quality_group",
        y="alcohol",
        hue="quality_group",
        ax=ax,
        palette="Set2",
        legend=False,
    )
    ax.set_xlabel("Градации фактора (оценка качества)")
    ax.set_ylabel(LABELS["alcohol"])
    ax.set_title("Однофакторный ANOVA: крепость по группам качества")
    savefig("anova_box.png")

    two = smf.ols("alcohol ~ C(quality_group) * C(type)", data=df).fit()
    two_table = anova_lm(two, typ=2)

    fig, ax = plt.subplots(figsize=(7.6, 4.8))
    means = df.groupby(["quality_group", "type"], observed=True)["alcohol"].mean().reset_index()
    sns.pointplot(
        data=means,
        x="quality_group",
        y="alcohol",
        hue="type",
        ax=ax,
        palette={"красное": "#8b1e3f", "белое": "#c4a35a"},
    )
```

```
    ax.set_xlabel("Группа качества")
    ax.set_ylabel("Средняя крепость, % об.")
    ax.set_title("Двухфакторный ANOVA: взаимодействие качества и типа вина")
    ax.legend(title="Тип")
    savefig("anova_two.png")


    group_stats = (
        df.groupby("quality_group", observed=True)["alcohol"]
        .agg(["count", "mean", "std", "median"])
        .reset_index()
        .to_dict(orient="records")
    )
    type_quality = (
        df.groupby(["type", "quality_group"], observed=True)["alcohol"]
        .agg(["count", "mean", "std"])
        .reset_index()
        .to_dict(orient="records")
    )


    results = {
        "n": int(len(df)),
        "n_red": int((df["type"] == "красное").sum()),
        "n_white": int((df["type"] == "белое").sum()),
        "sturges_k": sturges_bins(len(df)),
        "columns": num_cols,
        "desc": desc,
        "norm": norm,
        "contingency": ct.to_dict(),
        "expected": expected.round(2).to_dict(),
        "chi2": {
            "stat": float(chi2.statistic),
            "p": float(chi2.pvalue),
            "df": int(chi2.dof),
            "cramer": float(cramer),
        },
        "corr_tests": corr_tests,
        "pearson": pearson.round(4).to_dict(),
        "spearman": spearman.round(4).to_dict(),
        "kendall": kendall.round(4).to_dict(),
        "spurious": spurious,
        "linear": lin_info,
        "poisson": poi_info,
        "nonlinear": non_info,
        "anova": {
            "levene_stat": float(levene.statistic),
            "levene_p": float(levene.pvalue),
            "f": float(anova_one.statistic),
            "f_p": float(anova_one.pvalue),
            "kruskal_h": float(kruskal.statistic),
            "kruskal_p": float(kruskal.pvalue),
            "aov": aov_table.round(6).to_dict(),
            "tukey": {
                "data": tukey.summary().data,
                "reject": [bool(x) for x in tukey.reject],
            },
            "group_stats": group_stats,
            "type_quality": type_quality,
        },
        "anova2": two_table.round(6).to_dict(),
        "anova2_r2": float(two.rsquared),
        "anova2_fp": float(two.f_pvalue),
    }
    results = to_py(results)
    out = BASE / "results.json"
    out.write_text(json.dumps(results, ensure_ascii=False, indent=2), encoding="utf-8")
    print(f"n = {results['n']}, k_sturges = {results['sturges_k']}")
    print("saved", out)
    print("figures:", len(list(FIG.glob('*.png'))))
    return results



if __name__ == "__main__":
    main()
    try:
        from make_report import build_report


        build_report()
```

```
except ImportError:
    print("make_report.py не найден — отчёт будет собран отдельно")
```

Список литературы

1. Айвазян С. А. Методы эконометрики. — М.: Магистр: ИНФРА-М, 2010. — 512 с.
2. Cortez P., Cerdeira A., Almeida F., Matos T., Reis J. Wine Quality Data Set. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/186/wine+quality
3. Группировка и формула Стерджесса. http://univer-nn.ru/zadachi-po-statistike-primeri/gruppirovka-formula-sterdzhessa/
4. Проверка статистических гипотез в MS Excel. http://excel2.ru/articles/proverka-statisticheskih-gipotez-v-ms-excel
5. Таблицы сопряжённости. http://excel2.ru/articles/kriteriy-nezavisimosti-hi-kvadrat-v-ms-excel
6. Корреляция в Excel. https://excel2.ru/articles/korrelyaciya-i-kovariaciya-v-ms-excel
7. Регрессия в MS Excel. https://excel2.ru/articles/proverka-znachimosti-regressii-s-pomoshchyu-dispersionnogo-analiza-f-test
8. Однофакторный дисперсионный анализ. https://excel2.ru/articles/odnofaktornyy-dispersionnyy-analiz-one-way-anova-v-ms-excel
9. Vigen T. Spurious Correlations. http://www.tylervigen.com/spurious-correlations
10. MachineLearning.ru. Одномерная линейная регрессия; коэффициент детерминации; анализ регрессионных остатков.